

UNIVERSIDADE FEDERAL DE SERGIPE CENTRO DE CIÊNCIAS EXATAS E TECNOLOGIA DEPARTAMENTO DE COMPUTAÇÃO

Desenvolvimento de aplicações com arquitetura de microsserviços

Trabalho de Conclusão de Curso

João Paulo Feitosa Secundo



São Cristóvão – Sergipe

UNIVERSIDADE FEDERAL DE SERGIPE CENTRO DE CIÊNCIAS EXATAS E TECNOLOGIA DEPARTAMENTO DE COMPUTAÇÃO

João Paulo Feitosa Secundo

Desenvolvimento de aplicações com arquitetura de microsserviços

Trabalho de Conclusão de Curso submetido ao Departamento de Computação da Universidade Federal de Sergipe como requisito parcial para a obtenção do título de Bacharel em Ciência da Computação.

Orientador(a): Admilson de Ribamar Lima Ribeiro Coorientador(a): Rafael Oliveira Vasconcelos

Resumo

A escolha da arquitetura de uma aplicação envolve *tradeoffs* e decisões que podem ser complexas, sendo essencial entender seus benefícios, desvantagens e desafios para que possam ser aplicados ao contexto tratado. Embora não haja uma definição formal para a arquitetura de microsserviços, o presente trabalho destaca suas características mais frequentes, como componentização e alta complexidade; práticas comumente aplicadas, como CI/CD e monitoramento; e ferramentas frequentemente usadas no seu desenvolvimento e operação, por meio de pesquisa e revisão bibliográfica. Também foi identificado um tópico com espaço para mais discussões, sobre a prática de começar com uma arquitetura monolítica para só depois migrar para microsserviços. Ademais, foi desenvolvida uma aplicação web de *E-commerce* com arquitetura de microsserviços, utilizando várias das práticas e ferramentas apresentas. O resultado é um conjunto de características comuns, práticas bem consolidadas e ferramentas úteis no desenvolvimento de tais aplicações, assim como um exemplo prático que demonstra como essas podem ser aplicadas e como se comporta essa arquitetura.

Palavras-chave: arquitetura de software. microsserviços. desenvolvimento. práticas. ferramentas.

Abstract

Choosing an application architecture involves tradeoffs and decisions that can be complex, and it is essential to understand its benefits, disadvantages, and challenges so that they can be applied to the context in question. Although there is no formal definition for the microservices architecture, this paper highlights its most frequent characteristics, such as componentization and high complexity; commonly applied practices, such as CI/CD and monitoring; and tools frequently used in its development and operation, through research and bibliographic review. A topic with room for further discussion was also identified, on the practice of starting with a monolithic architecture and only later migrating to microservices. Furthermore, an *E-commerce* web application with microservices architecture was developed, using several of the practices and tools presented. The result is a set of common characteristics, well-established practices, and useful tools in the development of such applications, as well as a practical example that demonstrates how these can be applied and how this architecture behaves.

Keywords: software architecture. microservices. development. practices. tools.

Lista de ilustrações

Figura 1 – Exemplo de aplicação com arquitetura de microsserviços	18
Figura 2 – Exemplo de <i>pipeline</i> de CI/CD	39
Figura 3 – Ciclo DevOps	44
Figura 4 – Diagrama de componentes da aplicação exemplar	68
Figura 5 – Diagrama de pacotes da aplicação exemplar	69
Figura 6 – Diagrama de classes da aplicação exemplar	70
Figura 7 – Diagrama de sequência do caso de uso de realizar uma compra no carrinho.	71
Figura 8 – Visualização do dashboard do Grafana personalizado	75

Lista de abreviaturas e siglas

API Application Programing Interface - Interface para programação de aplicação

CPU Central Processing Unit - Unidade de Processamento Central

HTTP HyperText Transfer Protocol - Protocolo de transferência de hipertexto

DoS Denial of Service - Negação de serviço

RFC Request For Comments - Pedido de comentários

JSON JavaScript Object Notation - Notação de objeto JavaScript

DDD Domain-Driven Design - Projeto orientado a domínio

SSL Secure Socket Layer - Camada de soquete seguro

RPC Remote Procedure Call - Chamada de procedimento remoto

AWS Amazon Web Services - Serviços web da Amazon

IDE Integrated Development Environment - Ambiente integrado de desenvolvi-

mento

CI Continuous Integration - Integração contínua

CD Continuous Delivery e/ou Continuous Deployment - Entrega contínua e/ou

Implantação contínua

CDC Consumer-Driven contract - Contratos orientados ao consumidor

DVCS Distributed Version Control System - Sistema de controle de versão distribuido

CVCS Centralized Version Control System - Sistema de controle de versão centrali-

zado

ORM Object-Relational Mapping - Mapeamento objeto-relacional

AMQP Advanced Message Queuing Protocol - Protocolo avançado de enfileiramento

de mensagens

CLI *Command Line Interface* - Interface de Linha de Comando

AWS Amazon Web Services - Serviços Web da Amazon

GCP Google Cloud Platform - Plataforma na Nuvem do Google

SaaS Software as a Service - Software como serviço

PaaS Platform as a Service - Plataforma como serviço

IaaS Infrastrucute as a Service - Infraestrutura como serviço

Sumário

1	Intr	odução		• • • • • • • • • • • • • • • • • • • •	12			
	1.1	Objeti	vos		12			
		1.1.1	Objetivo	geral	12			
		1.1.2	Objetivo	os específicos	13			
	1.2	Metod	lologia		13			
2	Fundamentação teórica							
	Este	capítul	o apresent	ta uma introdução sobre as arquiteturas monolítica e de micros-				
	serv	iços						
	2.1	As apl	icações m	onolíticas	15			
		2.1.1	Benefíci	os	15			
		2.1.2	Limitaçõ	ŏes	16			
			2.1.2.1	Crescimento, velocidade de desenvolvimento, e manutenção .	16			
			2.1.2.2	Escalabilidade	16			
			2.1.2.3	Reutilização	16			
			2.1.2.4	Implantação	16			
			2.1.2.5	Confiabilidade e resiliência	17			
			2.1.2.6	Flexibilidade de tecnologias	17			
			2.1.2.7	Divisão de times	17			
	2.2	Os mi	crosserviç	os	17			
		2.2.1	Tipos de	microsserviços	18			
			2.2.1.1	Serviço de dados (data service)	18			
			2.2.1.2	Serviço de negócio (business service)	19			
			2.2.1.3	Serviço de tradução (translation service)	19			
			2.2.1.4	Serviço de ponta (edge service)	19			
			2.2.1.5	Serviço agregador (aggregator service)	19			
3	Trabalhos relacionados							
	3.1	Microservices, IoT and Azure: Leveraging DevOps and Microservice Architecture						
		to Del	iver SaaS	Solutions, por Familiar (2015)	20			
	3.2	A Sys	tematic M	Tapping Study on Microservices Architecture in DevOps, por				
		Wasee	m, Liang	e Shahin (2020)	21			
	3.3	Design, monitoring, and testing of microservices systems: The practitioners'						
		perspe	ctive, por	Waseem et al. (2021)	21			
	3.4	Buildi	ng Micros	services: Designing Fine-Grained Systems, por Newman (2021)	21			

		Continuous Delivery: reliable software releases through build, test, and deploy-	
		ment automation, por Humble e Farley (2010)	22
	3.6	Building Microservices with Micronaut, por Singh, Dawood e The Micronaut®	
		Foundation (2021)	22
	3.7	Microservices Patterns: with Examples in Java, por Richardson (2019)	22
	3.8	Building Microservices with ASP.NET Core, por Hoffman (2017)	23
	3.9	Building Event-Driven Microservices, por Bellemare (2020)	23
	3.10	The Art of Decoding Microservices, por Bhatnagar (2025)	24
	3.11	The Pains and Gains of microservices: a Systematic Grey Literature Review, por	
		Soldani, Tamburri e Heuvel (2018)	24
	3.12	How Do Microservices evolve? an Empirical Analysis of Changes in open-source	
		Microservice Repositories, por Assunção et al. (2023)	25
4	Cara	acterísticas, vantagens e desafios da arquitetura de microsserviços	27
	Este	capítulo apresenta as características e as vantagens da arquitetura de microsser-	
	viços	s, assim como os riscos, desafios e desvantagens que as acompanham.	
	4.1	Sistema distribuído	27
	4.2	Flexibilidade na escolha de ferramentas	28
	4.3	Alta velocidade de desenvolvimento	28
	4.4	Componentização	28
	4.5	Portabilidade	29
	4.6	Versionável e substituível	29
	4.7	Menor erosão de <i>software</i>	29
	4.7 4.8	Menor erosão de <i>software</i>	29 30
5	4.8		
5	4.8 Prát	Complexidade e desafios	30
5	4.8 Prát Este	Complexidade e desafios	30
5	4.8 Prát Este	Complexidade e desafios	30
5	4.8 Prát Este aplic	Complexidade e desafios	30 32
5	4.8 Prát Este aplic	Complexidade e desafios	30 32 32
5	4.8 Prát Este aplic	capítulo apresenta e discute práticas comumente seguidas no desenvolvimento de acções com arquitetura de microsserviços. Começar pela arquitetura monolítica 5.1.1 Requisito dos microsserviços: Provisionamento rápido	30 32 32 33
5	4.8 Prát Este aplic	Complexidade e desafios icas no desenvolvimento de aplicações com arquitetura de microsserviços	30 32 32 33 33
5	4.8 Prát Este aplic 5.1	capítulo apresenta e discute práticas comumente seguidas no desenvolvimento de cações com arquitetura de microsserviços. Começar pela arquitetura monolítica 5.1.1 Requisito dos microsserviços: Provisionamento rápido 5.1.2 Requisito dos microsserviços: Monitoramento básico 5.1.3 Requisito dos microsserviços: Implantação rápida	30 32 32 33 33 34
5	4.8 Prát Este aplic 5.1	icas no desenvolvimento de aplicações com arquitetura de microsserviços	30 32 32 33 33 34 34
5	4.8 Prát <i>Este aplic</i> 5.1 5.2 5.3	capítulo apresenta e discute práticas comumente seguidas no desenvolvimento de cações com arquitetura de microsserviços. Começar pela arquitetura monolítica 5.1.1 Requisito dos microsserviços: Provisionamento rápido 5.1.2 Requisito dos microsserviços: Monitoramento básico 5.1.3 Requisito dos microsserviços: Implantação rápida Microsserviços com Domain-Driven Design (DDD) A metodologia 12-fatores	30 32 33 33 34 34 35
5	4.8 Prát Este aplic 5.1 5.2 5.3 5.4	icas no desenvolvimento de aplicações com arquitetura de microsserviços	32 32 33 33 34 34 35 37
5	4.8 Prát Este aplic 5.1 5.2 5.3 5.4 5.5	capítulo apresenta e discute práticas comumente seguidas no desenvolvimento de aplicações com arquitetura de microsserviços. capítulo apresenta e discute práticas comumente seguidas no desenvolvimento de ações com arquitetura de microsserviços. Começar pela arquitetura monolítica 5.1.1 Requisito dos microsserviços: Provisionamento rápido 5.1.2 Requisito dos microsserviços: Monitoramento básico 5.1.3 Requisito dos microsserviços: Implantação rápida Microsserviços com Domain-Driven Design (DDD) A metodologia 12-fatores Produtos, não projetos Desenvolver e compartilhar ferramentas	32 32 33 33 34 34 35 37 37
5	4.8 Prát Este aplic 5.1 5.2 5.3 5.4 5.5 5.6	icas no desenvolvimento de aplicações com arquitetura de microsserviços	30 32 33 33 34 34 35 37 37

			5.7.1.2 <i>Build</i> rápido
			5.7.1.3 Automação de testes em novas integrações 40
			5.7.1.4 Servidor de integração
			5.7.1.5 Estabilidade do ramo principal
		5.7.2	Entrega/Implantação contínua (CD)
			5.7.2.1 Estratégias de lançamento
	5.8	DevOp	s
	5.9	Organi	zação de código
		5.9.1	Monorepo
		5.9.2	Multirepo
	5.10	Implan	tação em contêineres
	5.11	Testes	
		5.11.1	Testes de unidade
		5.11.2	Testes de serviço
		5.11.3	Testes <i>end-to-end</i> (ponta a ponta)
		5.11.4	Testes, testes e mais testes
	5.12	Comur	iicação
	5.13	APIs .	
		5.13.1	Contratos de dados
		5.13.2	Formatos de dados
		5.13.3	Códigos de status de respostas HTTP
		5.13.4	API Gateway
		5.13.5	Segurança em APIs
		5.13.6	<i>Caching</i>
		5.13.7	Comprimir os dados
		5.13.8	Documentação
		5.13.9	Paginar e filtrar
	5.14	Observ	rabilidade e Monitoramento
		5.14.1	<i>Logs</i> (registros)
		5.14.2	Métricas
		5.14.3	Tracing (rastreamento)
6	Ferr	amenta	s para desenvolvimento de microsserviços
			apresenta ferramentas frequentemente usadas e que cumprem propósitos
		_	no desenvolvimento de aplicações com arquitetura de microsserviços.
	6.1		os em nuvem
	6.2	_	vorks e linguagens de programação
		6.2.1	Java e Spring Boot
		6.2.2	Python e Flask ou Django
		6.2.3	Golang
			-

		6.2.4	JavaScript/TypeScript com Node.js e Express	57			
		6.2.5	C# e .NET	57			
	6.3	Servide	ores Web	58			
		6.3.1	Nginx ou Apache HTTP Server	58			
	6.4	Bancos	s de dados persistentes - SQL e NoSQL	58			
	6.5	Bancos	s de dados em memória - Memcached e Redis	59			
	6.6	Integra	ção contínua e Entrega Contínua (CI/CD)	60			
		6.6.1	Sistemas de controle de versão	60			
		6.6.2	Plataformas para CI/CD	60			
		6.6.3	Servidores de integração	61			
	6.7	Comur	nicação	62			
		6.7.1	RPC - gRPC	62			
		6.7.2	Sistemas de mensagens	62			
			6.7.2.1 Sistemas de mensagens em provedores na nuvem	63			
	6.8	Contei	nerização	63			
		6.8.1	Gerenciamento de contêineres com Kubernetes	64			
	6.9	Observ	vabilidade e Monitoramento	65			
		6.9.1	Métricas - Prometheus e Grafana	65			
		6.9.2	Logging - Grafana Loki	65			
		6.9.3	Logging - Graylog	66			
		6.9.4	Tracing (rastreamento) - Jaeger	66			
7	Apli	cação e	xemplar com arquitetura de microsserviços	67			
	Este	capítul	o apresenta a aplicação exemplar com arquitetura de microsserviços				
	dese	nvolvida	\imath .				
	7.1	.1 A aplicação e a divisão em microsserviços					
	7.2	Prática	s, ferramentas e padrões usados	71			
		7.2.1	Frameworks e linguagens de programação	71			
		7.2.2	Servidor web e API gateway	71			
		7.2.3	Bancos de dados e descentralização dos dados	71			
		7.2.4	Metodologia 12-fatores	72			
		7.2.5	Contêinerização e orquestração de contêineres	72			
		7.2.6	CI/CD	73			
		7.2.7	Organização do código - Multirepo	73			
		7.2.8	Comunicação síncrona	73			
		7.2.9	Comunicação assíncrona	74			
		7.2.10	Monitoramento	74			
		7.2.11	Padrões de projeto	75			
8	Con	clusão .		77			

Referências	
--------------------	--

1

Introdução

O crescimento da Internet e a onipresença da computação móvel tem mudado o jeito como *software* é desenvolvido nos últimos tempos. Todos que têm contato com a área do desenvolvimento de *software* provavelmente conhecem o termo *SaaS* (*Software as a Service*), ou *software* como um serviço. Entretanto, essa expressão significa mais do que apenas um modelo de negócio. A tendência que tem-se observado na indústria do *software* é a de oferecer *software* não mais como um pacote completo e fechado, mas sim como um pacote flexível e em constante melhoria, o que implica na mudança do foco dos desenvolvedores para a criação de aplicações modulares, e que permitam que mudanças sejam desenvolvidas e implantadas rápida, fácil e independentemente (XU et al., 2016; Oracle Corporation, 2021).

Essa mudança de foco implicou no surgimento de novas abordagens de arquitetura e organização de *software*, e uma dessas tem ganho grande popularidade na indústria do *software* por facilitar a criação de aplicações que são multilíngues, facilmente mantidas e implantadas, escaláveis, e altamente disponíveis. Inspirada na arquitetura orientada a serviços, ela se chama arquitetura de microsserviços, e é considerada por muitos profissionais da engenharia de *software* como a melhor maneira de arquitetar uma aplicação de *software* como um serviço atualmente. Entretanto, como tudo na computação, há um *trade-off* (uma troca), pois assim como há benefícios, também há desvantagens e desafios no emprego de uma arquitetura de microsserviços, os quais também são discutidos neste trabalho (Middleware Lab, 2021; WASEEM et al., 2021).

1.1 Objetivos

1.1.1 Objetivo geral

Analisar o desenvolvimento de aplicações com arquitetura de microsserviços.

1.1.2 Objetivos específicos

- Caracterizar a arquitetura de microsserviços;
- Apresentar e discutir práticas comumente usadas no desenvolvimento de aplicações com arquitetura de microsserviços;
- Apresentar ferramentas que são frequentemente usadas e que cumprem propósitos importantes em aplicações com arquitetura de microsserviços;
- Contextualizar essas ferramentas, apontando os problemas que resolvem e necessidades que suprem, assim como seus pontos positivos e negativos;
- Desenvolver uma aplicação exemplar com arquitetura de microsserviços, usando uma combinação das ferramentas e práticas apresentadas;

1.2 Metodologia

Para o desenvolvimento deste trabalho, inicialmente foi feita uma pesquisa exploratória sobre a arquitetura de microsserviços, com o objetivo de ganhar maior familiaridade com o tema. Depois de definidos os objetivos, foi iniciada uma pesquisa bibliográfica e os trabalhos mais relevantes foram filtrados e estudados. Os trabalhos julgados como mais relacionados ao tema tratado foram estudados mais a fundo e, com assistência dos modelos de inteligência artifical GPT-3.5 e GPT-4, foram resumidos para serem apresentados no capítulo de trabalhos relacionados.

Como foi constatado que não existe uma definição formal para a arquitetura de microsserviços, para caracterizá-la e para reunir práticas, foram extraídas dos trabalhos estudados as características ou práticas que apareceram com frequência ou que foram mencionadas como imprescindíveis pelos autores. Em seguida, essas características e práticas foram estudadas para então serem apresentadas de forma contextualizada, coesa e coerente neste trabalho.

Para apresentar e contextualizar as ferramentas frequentemente usadas em aplicações com arquitetura de microsserviços, uma nova pesquisa bibliográfica foi feita para conhecer e extrair as mais comumente usadas. Após isso, algumas dessas ferramentas e das práticas mencionadas anteriormente foram escolhidas para serem usadas no desenvolvimento da aplicação exemplar, de acordo com as necessidades resultantes da escolha do domínio dessa e tendo em mente os limites do contexto do desenvolvimento deste trabalho acadêmico.

Depois de grande parte da aplicação ser desenvolvida, com o novo conhecimento adquirido a partir dessa experiência prática de desenvolvimento, de bastantes pesquisas bibliográficas, e também de consultas aos modelos de inteligência artifical GPT-3.5 e GPT-4, foi escrita a parte do trabalho que apresenta ferramentas para o desenvolvimento de microsserviços. Por fim, depois de finalizada a aplicação exemplar, foram elaborados os diagramas apropriados para então ser

desenvolvida a parte do trabalho que a apresenta.

2

Fundamentação teórica

Este capítulo apresenta uma introdução sobre as arquiteturas monolítica e de microsserviços

Assim como este capítulo, a maioria dos engenheiros de *software* fala da arquitetura de microsserviços contrastando-a com a arquitetura monolítica, pois essa última é a abordagem mais comumente usada de arquitetura de *software*. Porém, é importante ter em mente que existem outros tipos de arquitetura que não se encaixam nem como de microsserviços nem como monolíticas, tal como as arquiteturas cliente-servidor e orientada a serviços (FOWLER, 2015a).

2.1 As aplicações monolíticas

Aplicações monolíticas, também chamadas de monólitos, são aplicações que possuem as camadas de acesso aos dados, de regras de negócios e de interface de usuário em um único programa em uma única plataforma. As aplicações monolíticas são autocontidas, totalmente independentes de outras aplicações e são feitas não para uma tarefa em particular, mas sim para serem responsáveis por todo o processo para completar determinada função, assim tendo pouca ou nenhuma modularidade. Elas podem ser organizadas das mais variadas formas e fazer uso de padrões arquiteturais, mas são limitadas em muitos outros aspectos, apresentados na subseção 2.1.2 (MONOLITHIC..., 2022).

2.1.1 Benefícios

O maior e melhor benefício da arquitetura monolítica é sua simplicidade. Os monólitos são simples para desenvolver, para implantar, e para escalar, ademais uma aplicação simples é uma aplicação mais fácilmente entendida pelos seus desenvolvedores, fato que por sí só já melhora sua manutenibilidade. Porém, vale ressaltar que simplicidade não necessariamente implica em facilidade.

Outra vantagem dos monólitos é a facilidade de desenvolvimento da sua infraestrutura. Por não possuirem dependências com outras aplicações e nem precisarem se dedicar a comunicação externa, os monólitos têm uma infraestrutura fácil de elaborar.

Entretanto, esses benefícios só são válidos até certo ponto. Depois que uma aplicação monolítica ou o time que a desenvolve cresce muito, ela pode se tornar um emaranhado complexo de funcionalidades que são difíceis de diferenciar, de separar e de manter, e os problemas dos monólitos começam a ficar evidentes (RICHARDSON, 2018).

2.1.2 Limitações

2.1.2.1 Crescimento, velocidade de desenvolvimento, e manutenção

Quando aplicações monolíticas chegam a certo tamanho, pode se tornar muito difícil desenvolver funcionalidades novas, ou mesmo prover manutenção às já existentes, devido a diversos problemas que começam a surgir, tais como: lentidão da IDE por conta do tamanho do código, prejudicando a produtividade dos desenvolvedores; sobrecarregamento do contêiner ou máquina que hospeda a aplicação, aumentando o tempo de início; e dificuldade de entendimento da aplicação e de realizar alterações nela, diminuindo a velocidade de desenvolvimento e a qualidade do código. Padrões de organização podem amenizar a situação, mas não eliminam o problema (RICHARDSON, 2018).

2.1.2.2 Escalabilidade

O escalamento de aplicações monolíticas também pode se tornar um problema, pois ele só pode ser feito em uma dimensão. É possível escalar o volume de operações executando mais cópias de um monólito, mas não é possível fazer isso com o volume dos dados, pois cada cópia precisará acessar todos os dados, o que aumenta o consumo de memória e o tráfego de entradas e saídas (*I/O*). Também não é possível escalar os componentes independentemente, não permitindo ajustar poder de processamento ou memória quando ou onde adequado (RICHARDSON, 2018).

2.1.2.3 Reutilização

O alto acoplamento entre as partes de aplicações monolíticas dificulta a reutilização delas, o que pode causar esforço e código repetidos.

2.1.2.4 Implantação

Realizar alterações em qualquer componente de um monólito implica na necessidade de reimplantar toda a aplicação, mesmo as partes que não têm ligação com as alterações, o que aumenta riscos associados a falhas na implantação e consequentemente desencoraja a prática de implantação contínua (RICHARDSON, 2018).

2.1.2.5 Confiabilidade e resiliência

O alto acoplamento existente entre as partes da aplicação monolítica permite que falhas relativamente pequenas possam prejudicar toda a aplicação, inclusive as partes que não tiveram relação com a falha.

2.1.2.6 Flexibilidade de tecnologias

As escolhas de tecnologias para novas funcionalidades são mais limitadas - um projeto tende a usar apenas um certo grupo de tecnologias porque realizar *upgrades* ou mudanças de tecnologias é uma tarefa complexa e pode causar problemas de compatibilidade (RICHARDSON, 2018).

2.1.2.7 Divisão de times

Quando um monólito alcança determinado tamanho, é desejável dividir os desenvolvedores em times que têm foco em partes funcionais ou do domínio específicas da aplicação. Entretanto, ter times separados no desenvolvimento de uma mesma aplicação monolítica é mais difícil e menos proveitoso, porque nunca serão totalmente independentes, visto que precisam coordenar o desenvolvimento e as implantações da aplicação (RICHARDSON, 2018).

2.2 Os microsserviços

Microsserviços é uma abordagem de arquitetura de *software*. Aplicações com uma arquitetura de microsserviços são separadas em partes, chamadas de microsserviços, que são classificadas em tipos (apresentados na subseção 2.2.1) e se comunicam por meio de uma rede. Microsserviços oferecem capacidades de negócio (funcionalidades relacionadas às regras de negócio da aplicação) ou capacidades de plataforma (funcionalidades relacionadas ao ambiente de execução da aplicação), tratando um aspecto em particular da aplicação. Eles se comunicam por meio de APIs bem definidas, contratos de dados e configurações. O "micro" em microsserviços faz referência não ao tamanho do serviço, mas sim ao seu escopo de funcionalidade, pois trata-se de oferecer apenas uma determinada funcionalidade, tornando-se especialistas nela. Assim sendo, microsserviços não necessariamente devem ser pequenos em tamanho, mas fazem apenas uma tarefa e a fazem bem (FAMILIAR, 2015; NEWMAN, 2021).

Sendo especialistas em apenas uma tarefa, microsserviços têm características e comportamentos que os diferenciam de outras arquiteturas orientadas a serviços, os quais serão discutidos no Capítulo 4.

A Figura 1 exemplifica uma aplicação com arquitetura de microserviços. Inicialmente os usuários da aplicação (camada *Clients*) fazem requisições à API para obter as informações desejadas. O *API Gateway* é reponsável por gerenciar as chamadas aos microsserviços e

fará as devidas requisições para os devidos microsserviços (localizados na camada *Container Orchestration*). Esses microsserviços, então, executarão a lógica apropriada de acordo com a requisição recebida, possivelmente usando informações registradas no banco de dados apropriado (camada *Data Store*).




Figura 1 – Exemplo de aplicação com arquitetura de microsserviços

Fonte: Oracle Corporation (2021)

2.2.1 Tipos de microsserviços

2.2.1.1 Serviço de dados (data service)

Tipo de serviço de mais baixo-nível. É responsável por receber e tratar dados, assim fornecendo acesso a determinado domínio e suas regras. Quando um serviço de dados realiza apenas operações relacionadas a um determinado domínio da aplicação, ele também é chamado de serviço de domínio.

2.2.1.2 Serviço de negócio (business service)

Em determinados momentos as operações precisam de mais de um modelo do domínio para serem representadas em um serviço. Assim, os serviços de negócio agregam dados e oferecem operações mais complexas. Eles englobam vários serviços de domínio e proveem uma funcionalidade do negócio de nível mais alto, podendo também encapsular domínios relacionados. Por exemplo, em um site de cursos *online*, um serviço de negócio poderia prover uma funcionalidade chamada "Matricular Aluno", que envolveria as operações de inserir aluno no serviço de cursos, inserir aluno no serviço de pagamento, e inserir aluno no serviço de gamificação.

2.2.1.3 Serviço de tradução (translation service)

Um serviço de tradução é um intermediário entre a aplicação e um recurso externo, provendo uma forma de acessar esse recurso. No caso desse serviço externo sofrer mudanças, pode-se realizar as alterações consequentemente necessárias em apenas um lugar, nesse serviço de tradução. Por exemplo, a aplicação pode consumir uma API externa por meio do serviço de tradução, pedindo para que ele faça uma requisição para essa API, e então recebendo a resposta.

2.2.1.4 Serviço de ponta (edge service)

É um serviço que serve diretamente ao cliente, sendo customizado para atender necessidades específicas desse cliente. Por exemplo, pode existir um serviço de ponta para clientes móveis e outro serviço de ponta para clientes web.

2.2.1.5 Serviço agregador (aggregator service)

Esse tipo de serviço consolida ou agrega dados de vários serviços em uma única requisição ou resposta, simplificando as interações com o cliente e reduzindo o número de chamadas necessárias por meio da rede.

3

Trabalhos relacionados

3.1 Microservices, IoT and Azure: Leveraging DevOps and Microservice Architecture to Deliver SaaS Solutions, por Familiar (2015)

Esse livro oferece um guia prático para a adoção de processos de entrega contínua de alta velocidade, visando criar soluções de *software* como serviço (SaaS) confiáveis e escaláveis. Essas soluções são projetadas e construídas utilizando uma arquitetura de microsserviços, implantadas no provedor de nuvem Azure e gerenciadas por meio de automação.

Como explicado no livro, microsserviços fazem uma coisa e fazem bem. Eles representam capacidades de negócio definidas usando o projeto orientado a domínio (DDD), são testados a cada passo do *pipeline* de implantação, e lançados por meio de automação como serviços independentes, isolados, altamente escaláveis e resilientes em uma infraestrutura em nuvem distribuída. Além disso, cada microsserviço pertence a um time único de desenvolvedores, que trata o desenvolvimento do microsserviço como um produto, entregando *software* de alta qualidade em um processo rápido e iterativo com envolvimento do cliente e satisfação como métrica de sucesso.

Em contraste com o presente trabalho, Familiar (2015) não aborda práticas e ferramentas usadas no desenvolvimento de microsserviços.

3.2 A Systematic Mapping Study on Microservices Architecture in DevOps, por Waseem, Liang e Shahin (2020)

Esse trabalho tem o objetivo de sistematicamente identificar, analisar, e classificar a literatura sobre microsserviços em DevOps. Inicialmente o leitor é contextualizado no mundo dos microsserviços e a cultura DevOps. Os autores usam a metodologia de pesquisa de um mapeamento sistemático da literatura publicada entre Janeiro de 2009 e Julho de 2018. Após selecionados 47 estudos, é feita a classificação deles de acordo com os critérios definidos pelos autores, e então é feita a discussão sobre os resultados obtidos - são expostos a quantidade de estudos sobre determinados tópicos em microsserviços, problemas e soluções, desafios, métodos de descrição, padrões de projeto, benefícios, suporte a ferramentas, domínios, e implicações para pesquisadores e praticantes. Por fim, são mapeados os desafios enfrentados e as soluções empregadas para os resolver.

Em contraste com o presente trabalho, Waseem, Liang e Shahin (2020) não abordam as características dos microsserviços ou ferramentas para os desenvolver.

3.3 Design, monitoring, and testing of microservices systems: The practitioners' perspective, por Waseem et al. (2021)

Esse trabalho tem o objetivo de entender como sistemas de microsserviços são projetados, monitorados e testados na indústria. Foi conduzida uma pesquisa relativamente grande que obteve 106 respostas e 6 entrevistas com praticantes de microsserviços e os resultados obtidos identificam os desafios que esses praticantes enfrentam e as soluções empregadas no projeto, monitoramento e teste de microsserviços. Também é feita uma discussão profunda sobre os resultados, da perspectiva dos praticantes, e sobre as implicações para pesquisadores e praticantes.

Em contraste com o presente trabalho, Waseem et al. (2021) não abordam as características dos microsserviços ou ferramentas usadas para os desenvolver.

3.4 Building Microservices: Designing Fine-Grained Systems, por Newman (2021)

Newman (2021) explora os conceitos fundamentais da arquitetura de microsserviços, oferecendo uma abordagem prática para projetar, implementar e gerenciar aplicações escaláveis com essa arquitetura. O autor também fornece diretrizes sobre como dividir uma aplicação monolítica em serviços menores e independentes, discutindo os benefícios e desafios dessa arquitetura desde a modelagem até a implantação.

Entretanto, diferente do presente trabalho, Newman (2021) não discute ferramentas para a implementação dos conceitos e práticas discutidas, focando em ideias em vez de tecnologias, pois reconhece que detalhes de implementação e ferramentas estão sempre em mudança.

3.5 Continuous Delivery: reliable software releases through build, test, and deployment automation, por Humble e Farley (2010)

Esse livro aborda a integração contínua no desenvolvimento de *software* moderno e tem como objetivo melhorar a colaboração entre as equipes responsáveis pela entrega de software. Ele aborda uma ampla gama de tópicos, desde gerenciamento de configuração, controle de versão e planejamento de lançamentos até técnicas de automação para construção, teste e implantação de software; tópicos esses que são muito relevantes no desenvolvimento de aplicações com arquitetura de microsserviços. O livro destaca que esses processos, muitas vezes vistos como secundários à programação, são essenciais para o sucesso da entrega de software e podem ter um grande impacto nos custos de produção e na eficiência do produto.

Em contraste com o presente trabalho, esse livro não se aprofunda em tópicos de arquitetura de *software*, porém é bastante relevante para qualquer sistema sendo desenvolvido com modelo de *software* como um serviço (SaaS).

3.6 Building Microservices with Micronaut, por Singh, Dawood e The Micronaut® Foundation (2021)

Esse livro serve como um guia prática de microsserviços para desenvolvedores Java, abordando desde os conceitos fundamentais e preocupações comuns dos microserviços até a implementação prática com o Micronaut, um *framework* de código aberto, baseado na JVM, e projetado para facilitar a criação rápida e eficiente de microserviços. O livro também aborda aspectos de implantação e manutenção, além de introduzir o uso do Micronaut no contexto de Internet das Coisas (IoT). Diferente do presente trabalho, ele foca em um único *framework* e linguagem para a implementação de uma arquitetura de microsserviços.

3.7 Microservices Patterns: with Examples in Java, por Richardson (2019)

Esse livro é um guia abrangente que aborda a arquitetura de microsserviços, discutindo 44 padrões reutilizáveis para o desenvolvimento e implantação de aplicações com arquitetura de

microsserviços de alta qualidade, oferecendo também exemplos práticos na linguagem Java.

O autor inicia discutindo os desafios das arquiteturas monolíticas tradicionais e os benefícios potenciais dos microsserviços, fornecendo estratégias práticas para a decomposição de serviços e a comunicação entre eles, também enfatizando a importância de desenvolver serviços prontos para produção, abordando tópicos como implantação, monitoramento e manutenção de microsserviços. Diferente do presente trabalho, esse livro foca apenas em padrões para o desenvolvimento dos microsserviços e com a linguagem Java.

3.8 Building Microservices with ASP.NET Core, por Hoffman (2017)

Esse livro é um guia prático que ensina como criar, testar, compilar e implantar microsserviços utilizando o *framework* da Microsoft gratuito e de código aberto ASP.NET Core. A obra aborda conceitos fundamentais como desenvolvimento orientado a testes e *API-first*, comunicação entre serviços por meio da criação e consumo de serviços de apoio, como bancos de dados e filas, e a construção de microsserviços que dependem de fontes de dados externas.

Diferente do presente trabalho, o autor explora o uso apenas do *framework* ASP.NET Core para o desenvolvimento de aplicações web projetadas para serem implantadas na nuvem, destacando práticas recomendadas para a criação de serviços que consomem ou são consumidos por outros serviços, aceitam configurações externas e implementam medidas de segurança eficazes.

3.9 Building Event-Driven Microservices, por Bellemare (2020)

Esse livro é um guia prático que aborda a construção de microserviços orientados a eventos para gerenciar e escalar dados organizacionais em tempo real. O autor explora como arquiteturas orientadas a eventos podem melhorar a agilidade e a escalabilidade dos sistemas, especialmente quando integradas a microserviços. Também são discutidos padrões de integração, desde os mais básicos até os altamente escaláveis, como Captura de Dados de Alteração (*Change Data Capture* - CDC) e o padrão de tabela de *outbox*, essenciais para transformar uma arquitetura de microserviços em um sistema orientado a eventos confiável. Além disso, o autor também aborda conceitos de *design* de eventos, padrões de processamento de *streams* e a integração de microsserviços orientados a eventos com sistemas baseados em requisição e resposta.

Diferente do presente trabalho, esse livro tem foco em como as arquiteturas de microsserviços e orientada a eventos podem ser mescladas de modo a permitir o desenvolvimento de sistemas capazes de lidar com volumes de dados em larga escala nas unidades de negócio de uma organização.

3.10 The Art of Decoding Microservices, por Bhatnagar (2025)

Esse livro oferece uma visão detalhada sobre a arquitetura de microserviços, abordando como projetar, construir e gerenciar sistemas com essa arquitetura, incluindo exemplos práticos. A obra é voltada para profissionais de tecnologia, especialmente aqueles que buscam adotar microserviços para construir aplicações escaláveis e resilientes. Os autores explicam as vantagens de dividir uma aplicação monolítica em serviços independentes, detalhando os aspectos técnicos de como os microserviços podem ser implementados com eficiência.

Os autores exploram práticas essenciais como o *design* de APIs, integração de serviços, comunicação entre microsserviços e como lidar com desafios frequentes, como a consistência de dados e a gestão de transações distribuídas. Além disso, discutem a importância de ferramentas de orquestração e automação no ciclo de vida dos microsserviços, abordando aspectos de CI/CD, testes e monitoramento, assim como questões de segurança e a importância de projetar sistemas de monitoramento eficazes para favorecer a operação contínua e a detecção rápida de falhas.

O presente trabalho é similar a esse livro, ambos abordando conceitos, práticas e ferramentas relacionadas ao desenvolvimento de microsserviços, porém neste trabalho a profundidade é menor e também é apresentada uma aplicação exemplar para demonstração da arquitetura de microsserviços de forma prática.

3.11 The Pains and Gains of microservices: a Systematic Grey Literature Review, por Soldani, Tamburri e Heuvel (2018)

Esse artigo apresenta uma revisão sistemática da literatura cinzenta sobre os desafios e benefícios da adoção de uma arquitetura de microsserviços. Os autores buscaram preencher a lacuna entre o que é discutido na indústria e as pesquisas acadêmicas ainda em desenvolvimento. Para isso, analisaram 51 fontes da literatura cinzenta publicadas entre 2014 e 2017, incluindo blogs técnicos, artigos de conferências industriais e relatórios de empresas.

Os resultados mostram que a adoção de microsserviços traz diversos desafios, desde o *design* até a operação dos serviços. No *design*, há dificuldades em definir a granularidade ideal dos microsserviços, versionamento de APIs e implementação de segurança distribuída. No desenvolvimento, surgem problemas com consistência de dados, transações distribuídas e dificuldades na execução de testes de integração e desempenho. Já na operação, os principais desafios incluem monitoramento complexo, orquestração de serviços e alto consumo de rede e processamento.

Apesar desses desafios, os autores identificam uma série de benefícios associados aos microsserviços. No *design*, a arquitetura permite maior escalabilidade, tolerância a falhas e

compatibilidade com ambientes de computação em nuvem. No desenvolvimento, os microsserviços oferecem independência tecnológica, facilitam a implementação de técnicas de CI/CD e incentivam a reutilização de componentes. Na operação, os microsserviços permitem implantação rápida, escalabilidade horizontal e isolamento de falhas, tornando as aplicações mais resilientes.

O estudo conclui que, embora os microsserviços ofereçam benefícios significativos, sua adoção exige boas práticas e ferramentas adequadas para mitigar os desafios identificados. A pesquisa contribui tanto para pesquisadores, ao fornecer um panorama dos problemas e vantagens dessa arquitetura, quanto para profissionais da indústria, ao reunir percepções práticas sobre a implementação de microsserviços em larga escala.

Diferente do presente trabalho, esse artigo foca na literatura cinzenta para determinar as práticas, benefícios e desafios característicos da arquitetura de microsserviços; e também não trata de ferramentas que podem ser usadas para os desenvolver.

3.12 How Do Microservices evolve? an Empirical Analysis of Changes in open-source Microservice Repositories, por Assunção et al. (2023)

Esse artigo investiga como os microsserviços evoluem ao longo do tempo, por meio da análise de 7.319 *commits* em 11 sistemas de código aberto, buscando entender se os microsserviços realmente evoluem de forma independente, como previsto pelo modelo arquitetural, ou se há interdependências significativas entre eles.

A motivação do estudo é que apesar de os microsserviços teoricamente oferecerem modularidade, escalabilidade e independência, na prática sua manutenção e evolução podem ser mais complexas do que o esperado. O artigo, então, busca responder duas questões principais: como os sistemas baseados em microsserviços evoluem e por que essa evolução acontece dessa forma. Para isso, os pesquisadores classificaram as alterações realizadas nos sistemas em três tipos: técnicas (como atualizações de bibliotecas e configurações), de serviços (relacionadas à lógica de negócio) e diversas (mudanças que não afetam diretamente o código).

Os resultados mostram que, na maioria dos sistemas analisados, a evolução dos microsserviços é predominantemente técnica, com um grande número de *commits* voltados para ajustes de infraestrutura e configuração, em vez de mudanças na lógica de negócio. Além disso, embora os microsserviços sejam projetados para operar de forma independente, os dados revelam que, na prática, eles raramente evoluem isoladamente. De acordo com os autores, essa interdependência ocorre principalmente devido a APIs compartilhadas, mudanças arquiteturais globais e ajustes de infraestrutura.

Outra descoberta importante é que a forma como os microsserviços evoluem muda ao

longo do tempo. Nos estágios iniciais de desenvolvimento de um sistema, há muitas mudanças relacionadas à lógica de negócio, refletindo o processo de construção dos serviços. No entanto, conforme o sistema amadurece, as alterações passam a ser majoritariamente técnicas, sendo focadas em manutenção, escalabilidade e ajustes estruturais. Isso sugere que, com o tempo, os desafios da evolução dos microsserviços deixam de ser sobre inovação e passam a envolver a sustentação e a manutenção da arquitetura.

O estudo conclui que, embora os microsserviços sejam teoricamente projetados para oferecer independência, a realidade é mais complexa, muitas vezes havendo forte interdependência entre serviços. Dessa forma, a fim de facilitar a manutenção dos sistemas ao longo do tempo, faz-se importante o estudo e aplicação de boas práticas e ferramentas no desenvolvimento da arquitetura de microsserviços, tópicos os quais não são abordados no artigo em questão, entretanto são abordados no presente trabalho, que foca justamente no desenvolvimento dos microsserviços.



Características, vantagens e desafios da arquitetura de microsserviços

Este capítulo apresenta as características e as vantagens da arquitetura de microsserviços, assim como os riscos, desafios e desvantagens que as acompanham.

Em geral não existe uma definição formal do que a arquitetura de microsserviços tem ou não tem, entretanto as características aqui apresentadas são características comuns observadas em arquiteturas que se encaixam como microsserviços. Assim sendo, nem todas as arquiteturas de microsserviços terão essas características, apesar de ser esperado que a maioria delas estejam presentes (FOWLER; LEWIS, 2014).

4.1 Sistema distribuído

A arquitetura de microsserviços forma naturalmente um sistema altamente distribuido, o que implica em alguns comportamentos e características. Uma delas é que qualquer chamada a um serviço está sujeita a falhas, portanto microsserviços devem ser projetados para serem resilientes, isso é, tolerantes a falhas e ter um tempo de recuperação razoável quando algum problema inevitavelmente acontecer (FAMILIAR, 2015).

Um benefício proveniente dessa distribuição é que microsserviços podem ser usados em soluções e cenários de uso diferentes, contudo, para tanto devem ser escaláveis, responsivos e configuráveis, para assim alcançar um bom desempenho independente do cenário de uso. Outro benefício dessa distribuição é a autonomia e o isolamento, o que significa que microsserviços são unidades auto-contidas de funcionalidade, com dependências de outros serviços fracamente acopladas, então podem ser projetados, desenvolvidos, testados e implantados independentemente de outros serviços (FOWLER; LEWIS, 2014; FAMILIAR, 2015).

Um desafio advindo dessa distribuição é que a comunicação é complexa e falível, geralmente dependendo de APIs e contratos de dados para definir como os microsserviços interagem, portanto eles são orientados-a-mensagens. Essa comunicação é melhor discutida na seção 5.12 e subseção 5.13.1 (FAMILIAR, 2015).

4.2 Flexibilidade na escolha de ferramentas

Como mencionado anteriormente, cada microsserviço disponibiliza suas funcionalidades por meio de APIs e contratos de dados em uma rede. Usando esse meio, a comunicação independe da arquitetura que o microsserviço faz uso, o que possibilita que cada microsserviço escolha seu sistema operacional, linguagem, serviços de apoio e demais ferramentas necessárias. Além disso, os microsserviços podem ser desenvolvidos usando uma linguagem de programação e estrutura que melhor se adapte ao problema que ele é projetado para resolver, possuindo mais flexibilidade. Entretanto, é importante notar que esse benefício pode resultar em um desafio, pois usar muitas ferramentas diferentes numa mesma aplicação aumenta exponencialmente sua complexidade de desenvolvimento e manutenção (Oracle Corporation, 2021; FAMILIAR, 2015).

4.3 Alta velocidade de desenvolvimento

Ter um time independente responsável por cuidar do ciclo de desenvolvimento e sua automação permite uma alta velocidade de desenvolvimento para os microsserviços, muito maior do que fazendo o equivalente para uma solução monolítica (FAMILIAR, 2015).

4.4 Componentização

Há muito tempo na indústria do *software* deseja-se construir sistemas apenas juntando componentes, assim como se faz no mundo físico. Na computação, um componente é definido como uma unidade de *software* que é atualizável e substituível independentemente. Apesar de ser muito comum o uso de pacotes e bibliotecas (padrão de projeto conhecido como *sidecar*), que podem ser considerados componentes, há maneiras diferentes de se componentizar *software* que são características dos microsserviços. Os microsserviços também podem utilizar pacotes e bibliotecas como componentes, contudo nessa arquitetura a maneira principal e mais eficiente para componentizar o *software* é justamente dividí-lo em microsserviços. Entretanto, essa divisão não é uma tarefa simples - pelo contrário, definir adequadamente os limites dos microsserviços é um dos desafios mais complexos e importantes desta arquitetura, mas pode ser facilitado pelo uso de abordagens bem consolidadadas de design de *software*, como o *Domain-Driven Design* (DDD), discutido na seção 5.2 (FOWLER; LEWIS, 2014).

Como mencionado acima, uma maneira de se alcançar certo nível de componentização em uma aplicação é pelo uso de múltiplas bibliotecas como componentes em um único processo, porém nesse caso uma mudança em qualquer desses componentes resulta na necessidade de reimplantar toda a aplicação. Por outro lado, se essa mesma aplicação é decomposta em múltiplos serviços, é provável que uma mudança em um serviço só obrigaria a reimplantação do mesmo serviço, assim tendo-se uma implantação mais simples e rápida. Ademais, por ter um alto nível de componentização e independência, os microsserviços são reusáveis por natureza e portanto

torna-se mais fácil criar soluções e produtos por meio da combinação de multiplos microsserviços (FOWLER; LEWIS, 2014; FAMILIAR, 2015).

Contudo, usar serviços dessa forma também traz algumas desvantagens. Uma delas é que será necessário considerar como mudanças em um serviço podem afetar seus consumidores. A abordagem tradicional para resolver esse problema é o uso de versionamento no serviço, entretanto essa prática não é bem-vista no mundo dos microsserviços. A melhor solução é projetar serviços para serem o mais tolerante possíveis a mudanças nos serviços a que consomem. Outra desvantagem é que a comunicação remota é muito mais complexa e custosa, portanto o método de comunicação escolhido deve ser implementado de modo flexível. Ademais, realocar responsabilidades entre componentes é mais difícil quando se trata de processos diferentes (FOWLER; LEWIS, 2014).

4.5 Portabilidade

A portabilidade de uma aplicação diz respeito a quão facilmente ela pode ser executada em diferentes ambientes de execução com variadas configurações de plataforma e infraestrutura. Ela não é inerente aos microsserviços, mas é facilitada por terem escopo e tamanho limitados. No entanto, faz-se necessário o uso de técnicas que aumentem essa portabilidade, como por meio de conteinerização, automação e externalização de configurações, para que assim os microsserviços possam ser implantados de forma fácil e eficiente em ambientes de execução variados. (FAMILIAR, 2015).

4.6 Versionável e substituível

Apesar do versionamento de microsserviços não ser recomendado por dificultar a operação e o entendimento deles, quando necessário é possível manter versões diferentes de um mesmo serviço executando ao mesmo tempo, assim proporcionando retrocompatibilidade e um processo de migração mais suave. Além disso, serviços podem ser atualizados ou mesmo substituidos sem ocasionar indisponibilidade do serviço, pelo uso de ferramentas de provisionamento e técnicas de implantação apropriadas. (FAMILIAR, 2015).

4.7 Menor erosão de software

A erosão de *software* é inevitável em qualquer aplicação - conforme um sistema cresce e envelhece, é natural que torne-se mais difícil dar-lhe manutenção. Porém, com componentes modularizados e organizados adequadamente, uma aplicação com arquitetura de microsserviços tende a erodir muito mais lentamente e crescer mais horizontalmente (em vez de verticalmente) do que uma não modularizada, favorecendo uma vida útil mais longa da aplicação.

4.8 Complexidade e desafios

O uso da arquitetura de microsserviços implica num grande aumento de complexidade não apenas na infraestrutura, mas também na segurança da aplicação e em muitas etapas do ciclo de desenvolvimento do *software*, incluindo o desenvolvimento, testes, monitoramento e *debug*. Além disso, o uso de diversas ferramentas diferentes, o que é comum nessa arquitetura, pode requerer o envolvimento de mais desenvolvedores e com mais experiência, também podendo ocasionar problemas por inexperiência deles. (RICHARDSON, 2021; FOWLER, 2015a; NEWMAN, 2021).

Ademais, um dos principais desafios no desenvolvimento de uma aplicação com arquitetura de microsserviços é a definição adequada dos limites de cada microsserviço, que pode ser facilitado pelo uso de abordagens bem consolidadadas de *design* de *software*, como o DDD. Outros desafios são: complexidade de projeto, complexidade operacional, consistência de dados, comunicação e manutenção. De acordo com Xu et al. (2016), os **três grandes desafios** do desenvolvimento de aplicações com arquitetura de microsserviços são (1) Como programar sistemas que consistem de um grande número de serviços executando em paralelo e distribuídos em um conjunto de máquinas, (2) Como reduzir a sobrecarga de comunicação causada pela execução de grandes números de pequenos serviços e (3) Como sustentar a implantação flexível de serviços em uma rede para conseguir realizar o balanceamento de carga. (FOWLER, 2015b).

Teorema CAP - Disponibilidade ou Consistência

CAP é um acrônimo para *Consistency, Availability and Partition tolerance* (Consistencia, Disponibilidade e Tolerância à partição), e o teorema CAP prova que é impossível, em um sistema distribuido, se ter consistência estrita de dados, disponibilidade contínua de todos os nós e tolerância à falhas de comunicação entre os nós ao mesmo tempo.

Um sistema distribuido que se mantém completamente disponível e tolera partições (AP) precisará lidar com a consistência eventual (em vez de estrita) dos dados durante uma falha. Um sistema distribuido que mantém consistência estrita dos dados e tolera partições (CP) precisará ficar indisponível enquanto se recupera de uma falha. Já um sistema que mantém consistência estrita dos dados e continua completamente disponível durante uma falha, na verdade não pode ser um sistema distribuido, pois sendo intolerante à partições, não poderia estar se comunicando por meio de uma rede. Assim, não se pode abandonar a tolerância à partições em sistemas distribuídos, reduzindo a escolha a consistência estrita ou disponibilidade contínua. Como toda aplicação com arquitetura de microsserviços naturalmente forma um sistema distribuido, é importante ter isso em mente ao escolher um modelo de gerenciamento de dados. (IBM, 2022; NEWMAN, 2021)

Percebe-se, então, que existem benefícios, desvantagens e desafios no desenvolvimento e manutenção de aplicações com arquitetura de microsserviços, normalmente só conseguindo

ser compensados em aplicações mais complexas, que se beneficiam melhor dessa arquitetura. Portanto, para determinar se adotar essa arquitetura é uma escolha sábia é necessário entender esses benefícios, desvantagens e desafios e aplicá-los ao contexto específico da aplicação e dos desenvolvedores (FOWLER, 2015b).

5

Práticas no desenvolvimento de aplicações com arquitetura de microsserviços

Este capítulo apresenta e discute práticas comumente seguidas no desenvolvimento de aplicações com arquitetura de microsserviços.

5.1 Começar pela arquitetura monolítica

Fowler (2015b) defende o uso de arquiteturas monolíticas para desenvolver novas aplicações. Mesmo os defensores dos microsserviços dizem que há custos e riscos no uso desta arquitetura, os quais desaceleram o time de desenvolvimento, assim favorecendo monólitos para aplicações mais simples. Esse fato leva a um argumento forte para a escolha de uma arquitetura monolítica mesmo se for acreditado que haverá benefícios mais tarde com o uso da arquitetura de microsserviços, por duas razões. A primeira é conhecida como *Yagni - You're not gonna need it*, ou "Você não precisará disso", um preceito do método ágil *ExtremeProgramming* que diz que uma capacidade que acredita-se ser necessária no futuro não deve ser implementada agora por quê "você não precisará disso". A segunda razão é que microsserviços só funcionarão bem se os limites forem muito bem estabelecidos, e para tanto, constrói-se um monólito primeiro para que se possa descobrir os limites antes de serem impostos grandes obstáculos neles pela divisão dos microsserviços (FOWLER, 2015b).

Além disso, Fowler (2014) também afirma que existem 3 pré-requisitos para se adotar uma arquitetura de microsserviços, e que é mais fácil lidar com as operações de um monólito bem definido do que de um ecossistema de pequenos serviços. Assim sendo, pode-se considerar uma boa prática começar pela arquitetura monolítica até que o sistema já esteja bem definido e estes pré-requisitos sejam atendidos - provisionamento rápido, monitoramento básico, e implantação rápida de aplicação - explicados na subseção 5.1.1, subseção 5.1.2 e subseção 5.1.3 respectivamente (FOWLER, 2014).

Já Tilkov (2015) contesta essa prática e afirma que não se deve começar pela arquitetura monolítica se o objetivo for uma arquitetura de microserviços. Ele afirma que o melhor momento para se pensar em dividir um sistema é justamente quando ele está sendo construido, e que

é extremamente difícil dividir um sistema *brownfield* (sistema desenvolvido a partir de outro pré-existente). Entretanto, ele reconhece que para dividir um sistema, deve-se conhecer muito bem o domínio, e que o cenário ideal para o desenvolvimento de microsserviços é quando se está desenvolvendo uma segunda versão de um sistema existente. Fowler (2015b) reconhece esses argumentos como válidos e reforça que existem, sim, benefícios de se começar por uma arquitetura de microsserviços, mas ainda existem poucas histórias de aplicações com arquiteturas de microsserviços e mais estudos de casos são necessários para saber como determinar a melhor escolha inicial de arquitetura (TILKOV, 2015; FOWLER, 2015b).

Lumetta (2018) afirma que para decidir a abordagem arquitetural inicial de uma aplicação é necessário considerar o contexto do negócio, da própria aplicação, e do time que a irá desenvolver, e que existem condições que configuram a melhor escolha. Ele descreve 3 condições que tornam a adoção de uma arquitetura de microserviços para uma nova aplicação uma boa escolha: (1) há necessidade de entrega de serviços rapida e independentemente; (2) parte da plataforma precisa ser extremamente eficiente; e (3) planeja-se aumentar o time. Ele também descreve 3 condições que tornam a adoção de uma arquitetura monolítica uma boa escolha: (1) o time ainda está em crescimento; (2) o produto sendo construído é não comprovado ou é uma prova de conceito; e (3) o time não tem experiência com microsserviços (LUMETTA, 2018).

Percebe-se então que existem tanto razões para se começar pelos microsserviços como razões para se começar com uma arquitetura mais simples. Porém, não foi observado um consenso sobre quais seriam exatamente as razões para adotar ou não uma arquitetura de microsserviços para uma nova aplicação desde o início de seu desenvolvimento. Há nesse ponto, portanto, espaço para mais discussões e pesquisas.

5.1.1 Requisito dos microsserviços: Provisionamento rápido

No contexto da computação, provisionamento significa disponibilizar um recurso necessário para o funcionamento de uma aplicação. Para produzir *software*, é necessário provisionar diversos recursos, tanto para os desenvolvedores quanto para o cliente. Naturalmente, o provisionamento torna-se mais fácil em plataformas de serviços de computação em nuvem - na AWS, por exemplo, para conseguir uma nova máquina, basta iniciar uma nova instância e acessá-la - um processo muito rápido quando comparado ao *on-premises*, onde seria necessário comprar uma nova máquina, esperar chegar, configurá-la e só então ela estaria pronta. Além disso, o provisionamento rápido requer automação de tarefas relacionadas (FOWLER, 2014).

5.1.2 Requisito dos microsserviços: Monitoramento básico

Toda aplicação precisa lidar com erros e problemas, porém em uma arquitetura distribuida, existem naturalmente mais lugares suscetíveis a problemas, por existirem mais componentes que são fracamente acoplados, estando sujeitos não só a falhas no código, mas também na

comunicação, na conexão, ou até falhas físicas. Portanto, o monitoramento é crucial nesse tipo de arquitetura, favorecendo uma rápida detecção dos problemas. Ademais, o monitoramento também pode ser usado para detectar problemas de negócio, como por exemplo uma redução nos pedidos de um *site* de vendas (FOWLER, 2014).

5.1.3 Requisito dos microsserviços: Implantação rápida

Na arquitetura de microserviços a implantação é feita separadamente para cada microsserviço. Com muitos serviços para gerenciar, ela pode se tornar uma tarefa árdua, portanto será novamente necessário um grande nível de automação nessa etapa, geralmente envolvendo um *pipeline* de implantação, que deve ser automatizado o máximo possível (FOWLER, 2014).

5.2 Microsserviços com *Domain-Driven Design* (DDD)

Como mencionado anteriormente, definir adequadamente os limites dos microsserviços é um dos desafios mais complexos e importantes no desenvolvimento de aplicações com tal arquitetura. De fato, isso também é verdade mesmo para arquiteturas mais simples, pois o conhecimento e modelagem do domínio são problemas intrínsecos do desenvolvimento de *software*, e não são habilidades facilmente ensinadas ou aprendidas. (EVANS, 2003)

Domain-Driven Design (DDD) é uma abordagem para o desenvolvimento de software que foca na modelagem do domínio do negócio de forma alinhada com suas regras e conceitos. Essa abordagem enfatiza a colaboração entre desenvolvedores e especialistas do domínio para criar um modelo preciso, reduzindo a complexidade e garantindo que o software reflita fielmente os processos do mundo real tratados. (EVANS, 2003)

Um dos pilares do DDD é a linguagem ubíqua, um vocabulário compartilhado que unifica a comunicação entre técnicos e especialistas do negócio. Além disso, a abordagem sugere dividir o sistema em contextos delimitados (*bounded contexts*), que favorecem modularidade e independência entre diferentes partes (e consequentemente equipes) da aplicação, o que se aplica especialmente bem aos microsserviços, por serem naturalmente componentizados. (EVANS, 2003)

Embora o uso do DDD possa trazer diversos benefícios para aplicações, especialmente as com arquiteturas complexas como a de microsserviços, sua implementação exige um profundo entendimento do domínio e competência na sua modelagem. Entretanto, quando aplicado corretamente, essa abordagem proporciona maior alinhamento com o negócio, melhor manutenção e evolução do *software* e favorece a independência de diferentes equipes. (EVANS, 2003)

5.3 A metodologia 12-fatores

A metodologia 12-fatores é um conjunto de diretivas para o desenvolvimento de aplicações com modelo de *software* como um serviço. Ela resume a experiência de diversos desenvolvedores experientes com o desenvolvimento desse tipo de aplicação, e tem foco no crescimento da aplicação, na dinâmica entres os times e na erosão do *software*. Cumprir esses fatores proporciona à aplicação: Um formato declarativo para automação de configuração de ambientes de execução, favorecendo a portabilidade; Adequação à implantação em plataformas na nuvem, evitando a necessidade de infraestrutura *on-premises*; Redução da divergência entre o ambiente de desenvolvimento e de lançamento, facilitando a entrega contínua; e Simplicidade no escalamento. Qualidades, essas todas, que são altamente desejáveis em microsserviços (WIGGINS, 2017; RODRIGUES, 2016)

É importante salientar que em um sistema distribuido como em uma aplicação com arquitetura de microsserviços, uma "aplicação" no contexto da metodologia 12-fatores constitui um único microsserviço, portanto o cumprimento e os benefícios da metodologia são separados para cada um deles. Posto isso, para alcançar os benefícios citados, os microsserviços devem seguir as seguintes diretivas:

- I. Base de código única Cada microsserviço deve ter uma base de código única e particular, com rastreamento utilizando controle de versão, e devem existir diferentes versões implantáveis, como por exemplo uma versão de homologação e uma de produção. Ter mais de um microsserviço compartilhando uma mesma base de código, como na abordagem *monorepo*, constitui uma violação dessa diretiva.
- II. Dependências portáteis e isoladas Cada microsserviço deve declarar suas dependências e isolá-las das de outros projetos. Isso é facilmente alcançado pelo uso de um gerenciador de pacotes, que mantém um arquivo declarando todas as dependências e gerencia o isolamento dos pacotes instalados na máquina. Um exemplo em projetos Python é o *pip*, que declara as dependências e o *virtualenv*, que lida com o isolamento dos pacotes instalados para cada projeto na máquina;
- III. Externalizar configurações Qualquer informação que varia de acordo com o ambiente de execução, como credenciais de acesso a um banco de dados por exemplo, devem ser armazenadas separadas do código, como em arquivos que não são rastreados pelo sistema de controle de versão ou em variáveis de ambiente:
- IV. Serviços de apoio são anexos Os microsserviços e sua lógica não devem depender de um serviço de apoio específico. Um serviço de apoio é qualquer serviço consumido por meio da rede como parte de sua operação usual, como um banco de dados. Caso o banco de dados usado seja o MySQL, por exemplo, deve ser possível trocar para o PostgreSQL, ou mesmo para um outro banco de dados na nuvem sem nenhuma mudança no código, apenas na configuração;
 - V. Separação entre construção, lançamento, e execução Deve-se separar estritamente

as etapas de construção, lançamento e execução. Na etapa de construção, usa-se os arquivos no repositório para criar um programa iniciável. Na etapa de lançamento, o programa iniciável combina-se com a configuração do ambiente de execução atual para criar um lançamento, que deve ser imutável e ter um identificador único (como, por exemplo, versão 1.6.2) para propósitos de controle de versão. Na etapa de execução, o lançamento e seus serviços de apoio são executados no ambiente apropriado.

VI. Processos *stateless* (sem estado) - O microsserviço deve ser executado como um ou mais processos que não armazenam estado e não dividem espaço de memória. Qualquer informação que precise persistir deve ser salva em serviços de apoio, geralmente um banco de dados, assim diminuindo o acoplamento e facilitando o escalamento;

VII. Vínculo de porta - Um microsserviço deve ser auto-contido, sendo ele mesmo responsável por expor e escutar em uma porta, em vez de depender de uma injeção no ambiente de execução, que é normalmente feita por um servidor web;

VIII. Simultaneidade - Além de não guardarem estado, os processos em um microsserviço devem ser independentes e categorizados em tipos diferentes. Dessa forma, é possível usar tipos diferentes de processos para atender cargas de trabalho diferentes e todos podem ser escalados independente e horizontalmente com facilidade.

IX. Descartabilidade - Os processos de um microsserviço devem ser descartáveis, podendo ser iniciados ou interrompidos rapidamente sem perda de informação importante;

X. Paridade de ambientes de execução - Deve-se manter todos os ambientes de execução o mais semelhantes possível. Essa é uma diretiva simples mas que envolve vários aspectos, em especial o intervalo entre o término do desenvolvimento de uma função e sua implantação; a diferença entre quem desenvolve e quem implanta; e a diferença entre as ferramentas e serviços de apoio usados para cada ambiente de execução. Esse intervalo e essas diferenças devem ser minimizados para aumentar a paridade entre os ambientes de execução, assim favorecendo a entrega contínua;

XI. Registros (*Logs*) - Registros devem ser tratatos como um fluxo de eventos e enviados para a saída padrão do processo, para que uma outra ferramenta lide com o tratamento e armazenamento;

XII. Processos administrativos - Processos que são executados pontualmente, como migrações de bancos de dados, devem ser versionados e constituem parte do lançamento. Eles devem ser executados facilmente num ambiente idêntico ao ambiente onde os processos do microsserviços estão sendo executados, aderindo também ao isolamento de dependências mencionado no fator II.

5.4 Produtos, não projetos

A maioria dos times de desenvolvedores trabalham sob o seguinte modelo de projeto: O objetivo é entregar uma peça de *software*, que quando entregue é considerada como completa. Após isso, o *software* é passado para um time de manutenção e o time que o desenvolveu é desfeito. Os praticantes de microsserviços tendem a evitar esse modelo, em vez disso adotando a ideia de que um time deve ser o dono de um produto - não projeto - durante todo seu ciclo de vida. Um exemplo de empresa que adota esse modelo é a Amazon, exercendo a ideia de "você constroi, você executa", na qual um time de desenvolvimento é totalmente responsável por um *software* em produção (um produto). Dessa forma, o time adquire pleno conhecimento de como seu produto se comporta e como seus usuários o utilizam, o que é importante pois também terá que realizar o suporte aos usuários do produto (FOWLER; LEWIS, 2014).

Essa prática também está ligada a separação da aplicação por capacidades de negócio - em vez de enxergar o *software* como um conjunto de funcionalidades a serem implementadas, cria-se uma relação entre os desenvolvedores e os usuários, na qual a questão é como o *software* pode auxiliar o usuário a aumentar a capacidade de negócio. Tal prática também pode ser aplicada em aplicações monolíticas, embora a divisão em microsserviços facilita a crição de relações entre os desenvolvedores de serviços e seus usuários (FOWLER; LEWIS, 2014).

5.5 Desenvolver e compartilhar ferramentas

Em vez de apenas usar um conjunto de padrões definidos para desenvolver microsserviços, é preferível produzir ferramentas úteis que outros desenvolvedores possam usar para resolver problemas similares aos que eles enfrentam. Essas ferramentas geralmente são extraídas de implementações maiores e compartilhadas com um grupo mais amplo, geralmente por meio de um modelo de código aberto. Com o Git e o GitHub se tornando ferramentas tão populares, práticas de código aberto estão cada vez mais comuns (FOWLER; LEWIS, 2014).

A Netflix é um exemplo de organização que segue essa filosofia. Compartilhar código útil e muito bem testado como bibliotecas incentiva outros desenvolvedores a resolver problemas semelhantes de maneiras semelhantes, ao mesmo tempo que mantém a possibilidade de escolher uma abordagem diferente, se necessário. As bibliotecas compartilhadas tendem a se concentrar em problemas comuns, como armazenamento de dados, comunicação entre processos e automação de infraestrutura (FOWLER; LEWIS, 2014).

5.6 Descentralização dos dados

Para o gerenciamento de dados, há a possibilidade de compartilhar um banco de dados entre diferentes microsserviços, porém isso é visto como um anti-padrão, pois microsserviços diferentes possuem necessidades distintas de armazenamento e acesso a dados. Dessa forma, uma

aplicação com arquitetura de microsserviços tem melhor isolamento, segurança e disponibilidade quando os microsserviços possuem um modelo de dados independente e gerenciam seu próprio banco de dados particular, inclusive tendo a possibilidade de usar sistemas de banco de dados diferentes. Além disso, os dados persistidos por esses bancos de dados particulares só devem ser acessados diretamente pelo serviço que o contém, e outros serviços que necessitem desses dados precisarão enviar uma requisição. Com cada serviço tendo seu próprio banco de dados, a escalabilidade dele e do seu banco de dados pode ser feita independentemente dos outros serviços. Assim, serviços que recebem poucos acessos podem ter bancos menos potentes e mais baratos, e vice-versa (Oracle Corporation, 2021; FOWLER; LEWIS, 2014).

Entretanto, essa descentralização tem implicações para o gerenciamento de fluxos de negócios que envolvem escritas em múltiplos bancos de dados. Geralmente a abordagem para se garantir consistência nas escritas é pelo uso de transações quando atualizando múltiplos recursos, porém o uso de transações resulta em um acoplamento temporal, o que pode resultar em problemas quando existem muitos serviços envolvidos em um único fluxo. Ademais, transações distribuídas são notoriamente difíceis de implementar, portanto arquiteturas de microsserviços normalmente realizam coordenação sem transações entre serviços, com reconhecimento claro de que consistência pode ser apenas consistência eventual (em vez de estrita) e que problemas serão lidados pela compensação de operações (FOWLER; LEWIS, 2014).

5.7 CI/CD

CI/CD é um método para entregar aplicações e mudanças nelas aos clientes com frequência, envolvendo CI e CD. CI é um acrônimo de *Continuous Integration* (integração contínua), e diz respeito à automação de como o novo código feito pelo desenvolvedor integra-se ao repositório principal. CD é um acrônimo de *Continuous Delivery* e/ou *Continuous Deployment* (entrega contínua e/ou implantação contínua). Entrega contínua diz respeito à automação de como o código no repositório se transforma em artefatos, que definem uma versão da aplicação e que são implantáveis num ambiente de execução. Implantação contínua diz respeito a automação de como esses artefatos são de fato implantados no ambiente de execução. Apesar de determinar essas definições para o presente trabalho, foram observadas algumas inconsistencias nas referências utilizadas tanto nas definições para os termos CI e CD quanto nos limites do que essas práticas englobam. Em particular para o termo CD, que pode significar *Continuous Delivery*, *Continuous Deployment*, ou mesmo os dois. (Harness Incorporated, 2021; Red Hat Incorporated, 2022)

Dito isso, não é importante se ater à uma definição específica; apenas deve-se entender que CI/CD é um processo, muitas vezes visualizado como um *pipeline*, que envolve a adição de um alto nível de automação e monitoramento no ciclo de vida do desenvolvimento de *software* como um serviço e auxilia profissionais de desenvolvimento e de operações a trabalhar mais eficiente e colaborativamente. Ademais, CI/CD faz com que processos sejam previsíveis e repetíveis,

diminuindo o espaço para erros humanos. Considerando que a automação e monitoramento são essenciais para diversas práticas recomendadas no desenvolvimento de microsserviços, CI/CD é uma prática de extrema importância (Red Hat Incorporated, 2022; GitLab Incorporated, 2022a).

Por fim, não existe uma estrutura ou um conjunto específico de passos que todo *pipeline* de CI/CD deve ter; a estrutura e os passos contidos dependem dos requisitos dos times envolvidos e da aplicação. No caso dos microsserviços, CI/CD é implementado para cada microsserviço separadamente, podendo ter configurações variadas para cada um. A Figura 2 ilustra uma possível estrutura de um *pipeline* de CI/CD.




Figura 2 – Exemplo de pipeline de CI/CD

Fonte: Autor

5.7.1 Integração contínua (CI)

CI (*Continuous Integration* - Integração contínua) é uma prática no desenvolvimento de *software* onde os desenvolvedores integram o código em um repositório compartilhado frequentemente. Muitos times afirmam que essa prática leva a uma grande redução nos problemas de integração e os permite desenvolver *software* coeso mais rapidamente. Além disso, melhora a identificação do progresso do desenvolvimento, facilita a identificação e remoção de falhas e *bugs*, e aumenta a experiência e a confiança do time nos testes e *build* do código desenvolvido.

A integração contínua por sí só requer apenas uma ferramenta de controle de versão para ser feita, mas existem práticas bem consolidadas na indústria do desenvolvimento de *software* que incrementam esse processo, apresentadas a seguir. (FOWLER, 2006).

5.7.1.1 Uso de apenas um repositório fonte

Deve haver apenas um repositório por projeto ou microsserviço, compartilhado por toda a equipe desenvolvedora e contendo tudo aquilo que é necessário para uma instalação rápida e funcional do ambiente de desenvolvimento. Isso inclui mas não é limitado a - código, *scripts*, migrações e esquemas de bancos de dados, arquivos de propriedades e configurações de IDE. Além disso, o conteúdo do repositório deve estar disponível para todos, assim aumentando a visibilidade e facilitando o monitoramento do progresso do conteúdo (GitLab Incorporated, 2022a; FOWLER, 2006).

5.7.1.2 Build rápido

Um *build* (construção) da aplicação trata-se da transformação dos arquivos no repositório em um programa iniciável. *Builds* lentos afetam negativamente a integração contínua, atrasando integrações e diminuindo a frequência do *feedback*. Além disso, todas as etapas do *build* devem ser simples de executar, idealmente por meio de um único comando (FOWLER, 2006).

5.7.1.3 Automação de testes em novas integrações

As integrações de cada novo *commit* no repositório devem ser testadas, o que pode ser uma tarefa árdua e demorada dependendo de como o *build* da aplicação é feito e da quantidade de testes, especialmente se feitos manualmente. Desse modo, deve-se elaborar uma bateria de testes, e executá-la de forma automática a cada novo *build*, para assim detectar falhas rapidamente e aumentar a qualidade do *software* (GitLab Incorporated, 2022a; FOWLER, 2006).

5.7.1.4 Servidor de integração

Muitas vezes não é possível (nem recomendado) executar todos os passos do *pipeline* de integração na máquina do desenvolvedor, seja por questões de tempo, de capacidade computacional ou pela falta de garantia de que o desenvolvedor realmente executará os passos. Nesses casos, recomenda-se providenciar um local que centralizará a integração do novo código desenvolvido com o repositório principal. Tal local é chamado de *CI Daemon*, ou servidor de integração, e ele é responsável por executar todos os passos do *pipeline* de integração, assim como disponibilizar informações e relatórios sobre os passos executados. Também é recomendado estabelecer condições para que a integração do novo código seja efetuada, tal como a execução bem-sucedida de todos os testes, assim garantindo que apenas o código que cumpra tais condições seja integrado e consequentemente aumentando a qualidade do código e do produto (FOWLER, 2006; HUMBLE; FARLEY, 2010).

5.7.1.5 Estabilidade do ramo principal

Um dos principais motivos para se usar a integração contínua é a garantia de que a equipe sempre estará trabalhando a partir de uma base de código estável. Se o ramo principal está instável, é tarefa de toda a equipe resolver o problema o mais rápido possível, pois nenhum código poderá ser desenvolvido a partir daquele ramo até que esteja estável e confiável novamente. Geralmente o melhor meio de resolver esse problema é reverter os *commits* problemáticos, mas se a solução for simples, integrar um novo *commit* pode ser suficiente. (FOWLER, 2006).

5.7.2 Entrega/Implantação contínua (CD)

CD significa entrega contínua e/ou implantação contínua, conceitos relacionados e às vezes usados alternadamente. Em ambos os casos, trata-se da automação de fases avançadas do *pipeline* de implantação. A entrega contínua é uma evolução da integração contínua e envolve todo o ciclo do projeto, até a criação da nova versão da aplicação, mas a implantação dessa nova versão no ambiente de execução ainda é feita manualmente. A implantação contínua engloba a entrega contínua e adiciona o passo de automatizar a implantação da nova versão no ambiente de execução. A finalidade da entrega contínua é garantir o mínimo de esforço na implantação de novas alterações, enquanto a da implantação contínua é sempre manter o ambiente de execução atualizado com as últimas alterações. A adoção da implantação contínua deve ser ponderada, pois para alguns negócios é preferível uma taxa de implantações mais baixa. A arquitetura de microsserviços tem uma ótima afinidade com a implantação contínua, por ser naturalmente modularizada e mais facilmente testável (GitLab Incorporated, 2022a; Red Hat Incorporated, 2022).

Os benefícios da entrega contínua incluem: risco reduzido na implantação, pois como as mudanças são menores, há menos possibilidades de problemas, e caso haja, o conserto é mais simples; visualização do progresso, que não será simplesmente por trabalho "completo", mas sim por trabalho entregue; e *feedback* do usuário mais rápida e frequentemente (FOWLER, 2013).

Anti-padrão em CD: gerenciamento manual de ambientes

Diferenças entre ambientes que deveriam ser iguais, ou o mais similares possível, por exemplo homologação e produção. Diferenças entre réplicas. Resulta em implantações não confiáveis. Deve-se tratar a configuração de ambiente como código, com versionamento e automatizado. (HUMBLE; FARLEY, 2010)

Anti-padrão em CD: implantação manual

Realizar os passos da implantação manualmente resulta em uma implantação lenta e propícia a erros. Recomenda-se automatizar a implantação o suficiente para que possa ser feita

com apenas o clique de um botão, ou, caso seu negócio permita, ser completamente automática. (HUMBLE; FARLEY, 2010)

Anti-padrão em CD: baixa frequência de implantação

Implantar o *software* com baixa frequência resulta em pouca colaboração e entendimento entre a equipe de desenvolvimento e a de operações. Quanto mais frequente é a implantação, menor é a dificuldade dela. (HUMBLE; FARLEY, 2010; FOWLER, 2011)

5.7.2.1 Estratégias de lançamento

Estratégias de lançamento dizem respeito a como atualizar uma aplicação em produção, e a escolha da estratégia depende de fatores como risco, tempo de inatividade e a necessidade de controle sobre a liberação de funcionalidades. Algumas estratégias fazem uso de *dark launching* (lançamento escuro), que significa que algumas funcionalidades estão disponíveis para alguns usuários sem que eles saibam, permitindo testes e monitoramento com usuários reais antes do lançamento completo. É importante notar que implantação (*deploy*) e lançamento (*release*) são conceitos distintos, embora frequentemente usados de forma intercambiável. Implantação refere-se à ação técnica de implantar a nova versão do *software* em um ambiente de execução, enquanto lançamento é o momento em que a versão é disponibilizada aos usuários, uma decisão que envolve considerações de negócio.

Ao separar implantação e lançamento, as equipes técnicas podem realizar implantações mais ágeis, por não depender de decisões de negócios. Isso permite que a área técnica trabalhe com mais autonomia e frequência nas implantações, enquanto a área de negócios ainda pode decidir o melhor momento para liberar a nova versão para o público, alinhando o lançamento com objetivos estratégicos. A seguir são apresentadas algumas estratégias comuns de lançamento.

Blue-Green Deployment

No *Blue-Green Deployment*, quando deseja-se lançar uma nova versão, são mantidos um ambiente de produção com a versão antiga (*Blue*) e um com a versão nova (*Green*). Para permitir uma transição suave entre versões para os usuários, o tráfego é redirecionado para o ambiente novo após a validação da nova versão, favorecendo uma atualização segura e diminuindo riscos. Além disso, caso ocorra algum problema, é possível rapidamente reverter para o ambiente antigo, sendo necessário apenas mudar o redirecionamento. (FOWLER, 2010)

Canary Release

No *Canary Release*, a nova versão é disponibilizada para um número gradual dos usuários. Inicialmente, a nova versão é implantada em uma parte restrita do ambiente de execução, sem tráfego significativo, permitindo testes preliminares. Em seguida, um subconjunto de usuários

é direcionado para essa versão, possibilitando a detecção de falhas ou problemas antes que a atualização afete todos os usuários. Se nenhum erro crítico for identificado, a distribuição da nova versão ocorre de forma progressiva, garantindo maior controle e diminuindo riscos. Essa abordagem permite um monitoramento mais eficiente do desempenho e da estabilidade da nova versão, também possibilitando uma fácil reversão (*rollback*) da implantação caso necessário, assim protegendo a experiência dos usuários. (SATO, 2014)

Feature Toggles

Com os *Feature Toggles*, também conhecidos como *Feature Flags*, funcionalidades podem ser ativadas ou desativadas sem a necessidade de modificar o código-fonte ou realizar novas implantações. Essa abordagem permite maior flexibilidade no lançamento de novas funcionalidades, facilitando testes A/B, lançamentos graduais e controle operacional de determinadas partes do sistema, inclusive podendo ser feitas de forma que o usuário decida se quer ou não usar a nova funcionalidade. Existem diferentes categorias de Feature Toggles, incluindo *Release Toggles*, que gerenciam a ativação progressiva de novas features; *Experiment Toggles*, que suportam testes controlados; *Ops Toggles*, que ajustam o comportamento do sistema em tempo de execução; e *Permissioning Toggles*, que regulam o acesso de usuários a funcionalidades específicas. No entanto, o uso excessivo desses *toggles* pode aumentar a complexidade do código, tornando essencial a adoção de boas práticas para seu gerenciamento, como a documentação clara e a remoção de *toggles* obsoletos. (HODGSON, 2017)


5.8 DevOps

Historicamente, existe uma diferença no foco do trabalho entre desenvolvedores e operadores que já está arraigada em muitas empresas que lidam com o desenvolvimento de *software*. Enquanto por um lado as equipes de desenvolvimento tentam ser o mais eficientes possível, entregando tarefas completas sempre que possível, por outro, a equipe de operações valoriza a estabilidade, considerando cada alteração como uma possível causa de problemas. Assim, uma equipe preza pela velocidade em novas funcionalidades, enquanto a outra, pela estabilidade. Com isso em mente, integrantes da indústria do desenvolvimento de *software* começaram a conceber um movimento, chamado DevOps, com o objetivo de alinhar o foco das equipes e favorecer o trabalho em conjunto para conseguir alcançar uma entrega contínua e ao mesmo tempo manter o *software* funcional no ambiente de execução.

DevOps, ilustrado na Figura 3, é um movimento cultural que visa a integração e otimização do processo de aprendizagem e colaboração entre os integrantes de equipes relacionadas ao desenvolvimento de *software*. Ao contrário do que alguns pensam, não se trata de um cargo ou de um conjunto de ferramentas, mas sim de uma visão organizacional de trabalho que tem o objetivo de automatizar o ciclo de desenvolvimento do *software* de modo que seja veloz, seguro

e integrado, com foco nas necessidades do usuário e *feedback* rápido. Práticas de DevOps, como integração e entrega contínua, são fundamentais para o sucesso de aplicações com arquitetura de microsserviços pelos benefícios que agrega ao time e ao desenvolvimento e operação da aplicação (GitLab Incorporated, 2022b).

Figura 3 – Ciclo DevOps



Fonte: Pennington (2020)

5.9 Organização de código

5.9.1 Monorepo

Monorepo é uma estratégia de organização de código onde usa-se apenas um repositório no sistema de controle de versionamento para gerenciar múltiplos projetos. Ela é usada por diversas grandes empresas como Google, Facebook e Microsoft para gerenciar inúmeros projetos que formam um repositório enorme. O benefício mais tangível dessa abordagem é a simplificação do gerenciamento do versionamento dos projetos - como todos ficam em apenas um repositório, é mais fácil entender o histórico de mudanças e acompanhar o estado da aplicação, também facilitando restaurações de estados anteriores (*rollbacks*). Segundo Brousse (2019), o uso dessa estratégia de organização de código também causa um impacto cultural nos times envolvidos

com os projetos, encorajando código consistente e de alta qualidade e melhorando a cognição e o trabalho em equipe deles. Por outro lado, essa estratégia é uma violação do fator I da metodologia 12-fatores e pode causar problemas, como pior desempenho da IDE e de ações como o *build* devido ao grande tamanho do repositório; sobrecarga do servidor de integração devido ao maior número de operações no repositório; aumento do acoplamento entre os projetos caso os desenvolvedores não sigam práticas adequadas para manter o acoplamento baixo; e aumento na complexidade da automação de processos relacionados a integração, entrega e implantação contínua. (FERNANDEZ; ACKERSON, 2022; SIWIEC, 2021; BROUSSE, 2019).

5.9.2 Multirepo

Multirepo, ou polirepo, é uma estratégia de organização de código onde usa-se múltiplos repositórios no sistema de controle de versionamento para o gerenciamento de múltiplos projetos. Na arquitetura de microsserviços isso geralmente significa ter um repositório para cada microsserviço e é a estratégia mais comum de organização de código. Suas vantagens em contraste com o monorepo incluem: tamanho razoável do repositório; escopo do repositório bem definido; definição de permissões diferentes para cada projeto; e operações no repositório têm melhor desempenho. Essa abordagem é mais adequada quando não há necessidade de gerenciar cuidadosamente a versão da aplicação como um todo e esse versionamento é transparente para os usuários (FERNANDEZ; ACKERSON, 2022).

5.10 Implantação em contêineres

Contêineres configuram isolamentos lógicos em uma máquina, sendo leves, altamente flexíveis e permitindo paradas, alterações e reinicios velozes. Depois de desenvolvido o microsserviço, é altamente recomendado que ele seja implantado em um contêiner, para assim favorecer sua padronização e portabilidade, também evitando interferências imprevistas com outros microsserviços. (Oracle Corporation, 2021).

5.11 Testes

Tradicionalmente, um *build* engloba tudo que é necessário para que um programa possa executar. Entretanto, só porque um programa executa não significa que ele fará o que é esperado. Para tanto, deve-se testar o programa, idealmente de forma automática e para toda funcionalidade, assim falhas e *bugs* podem ser descobertos antes de serem lançados. Existem inúmeros tipos e abordagens de testes de *software*, porém é impossível ter uma cobertura completa de testes. Trata-se, portanto, de quão testada é a aplicação - quanto mais bem testada, pelo uso de abordagens diversas e apropriadas, maior é a confiabilidade e a qualidade do sistema. Entretanto, é importante também não só automatizar a bateria de testes, mas também prezar pelo seu desempenho, pois

testes demorados tornam-se um obstáculo para a integração e *feedback* contínuos, portanto antes de sair criando vários testes complexos para a aplicação, deve-se avaliar se a confiabilidade resultante justifica a complexidade de implementação e execução. (FOWLER, 2006; NEWMAN, 2021)

Na arquitetura de microsserviços, o processo de testes torna-se mais abrangente, por haver mais pontos passíveis de falha, e mais complexo, por se tratar de um sistema altamente distribuido. Além disso, um microsserviço, de maneira isolada, também pode ser testado com tipos de testes comumente usados em aplicações monolíticas, como testes de unidade e de serviço.

5.11.1 Testes de unidade

Testes de unidade verificam funções ou métodos isoladamente, sem depender de serviços externos ou conexões de rede. Esse tipo de teste é voltado para desenvolvedores, ajudando-os a detectar *bugs* e facilitando a refatoração do código, por garantir que alterações estruturais não quebrem funcionalidades existentes. Além disso, esses testes têm custo muito baixo, tanto para implentar quanto para executar, então é muito difícil uma aplicação chegar a um ponto que tenha testes de unidade demais. Em específico para linguagens interpretadas, eles podem ser acionados automaticamente ao modificar arquivos, proporcionando ciclos de *feedback* mais rápidos (NEWMAN, 2021).

5.11.2 Testes de serviço

Testes de serviço são projetados para testar microsserviços diretamente, ignorando interfaces de usuário. Em aplicações monolíticas, isso envolveria testar classes que fornecem serviços à essa interface, enquanto em sistemas baseados em microserviços, cada teste de serviço foca nas capacidades individuais de um microsserviço. Esses testes aumentam a confiança no comportamento do serviço, contanto que o escopo seja isolado, isso é, qualquer falha detectada deve estar restrita ao microsserviço testado. Para garantir esse isolamento, muitas vezes é necessário substituir todas as dependências externas por simulações delas (*stubs*) (NEWMAN, 2021).

Alguns testes de serviço podem ser tão rápidos quanto testes unitários, mas a velocidade pode diminuir ao envolver bancos de dados reais ou conexões de rede com serviços simulados. Apesar de cobrirem um escopo maior que os testes unitários, tornando a identificação precisa de falhas mais difícil, eles ainda possuem menos variáveis do que testes de maior escala como os testes ponta a ponta, sendo assim mais confiáveis. (NEWMAN, 2021).

5.11.3 Testes *end-to-end* (ponta a ponta)

Testes ponta a ponta verificam o fluxo completo de uma determinada funcionalidade da aplicação, incluindo integrações externas, assim envolvendo múltiplos microsserviços. Newman

(2021) argumenta em seu livro "Building Microservices" que muitos desenvolvedores de microsserviços em escala dispensam testes ponta a ponta apesar do ótimo escopo que eles provêem, devido à grande quantidade de recursos que exigem para serem executados e por serem suscetíveis a problemas que não necessariamente tem relação com a funcionalidade testada, o que pode introduzir indeterminismo nos testes. É recomendado então usar testes ponta a ponta apenas quando o sistema não é muito grande, e a confiabilidade agregada por eles supera o custo de os manter. Conforme uma aplicação de microsserviços cresce, muitos desenvolvedores preferem aumentar a confiabilidade pelo uso de monitoramento avançado, estratégias de implantação cuidadosas e uso de contratos de dados orientados ao consumidor (CDCs) (NEWMAN, 2021).

5.11.4 Testes, testes e mais testes

Além de recomendar os tipos de testes comuns em monólitos, Familiar (2015) recomenda também testar os microsserviços conforme passam pelo *pipeline* de implantação, incluindo: **Testes internos**, que testam as funções internas do serviço, incluindo uso de acesso de dados, caching e relacionados; **Testes de serviço**, que testam serviços da API e seus modelos associados; **Testes de protocolo**, que testam o serviço a nível de protocolo, chamando a API usando o protocolo escolhido; **Testes de composição**, que testam o serviço em cooperação com outros serviços no contexto de uma solução; **Testes de escalabilidade e taxa de transferência**, que testam a escalabilidade e elasticidade do microsserviço implantado; **Testes de tolerância a falha**, que testam a capacidade do microsserviço de se recuperar após uma falha; e **Testes de penetração**, que consiste em envolver uma empresa terceirizada de segurança de *software* para realizar testes de penetração no sistema. (FAMILIAR, 2015)

5.12 Comunicação

No desenvolvimento de estruturas de comunicação entre diferentes processos, nota-se muitos produtos e abordagens que enfatizam o emprego de grande inteligência no próprio mecanismo de comunicação. Um exemplo disso é o Enterprise Service Bus (ESB), onde os mecanismos dessa abordagem geralmente incluem recursos sofisticados para roteamento, tratamento e transformação de mensagens e aplicação das regras de negócios (FOWLER; LEWIS, 2014).

A comunidade de microsserviços favorece uma abordagem alternativa - *endpoints* inteligentes e canais simples. Os microsserviços visam ser o mais desacoplados e coesos possível - eles possuem sua própria lógica de domínio e agem mais como filtros - recebendo uma solicitação, aplicando a lógica conforme apropriado e produzindo uma resposta. Isso geralmente é feito usando protocolos REST simples em vez de protocolos complexos como *Web Service Choreography* ou orquestração por uma ferramenta central (FOWLER; LEWIS, 2014).

O uso de APIs em conjunto com requisições HTTP é o método mais usado para realizar

comunicação síncrona na arquitetura de microsserviços. Uma requisição HTTP é feita por um cliente (ou consumidor) para um dado provedor em um endereço, com o propósito de acessar um recurso dele. Por usar o *Transmition Control Protocol* (TCP), é um método de comunicação confiável, mas não tão eficiente quanto poderia ser (FOWLER; LEWIS, 2014).

Para comunicação assíncrona, sistemas de mensagens são amplamente usados. Quando um serviço precisa enviar informações a outro de modo assíncrono, ele envia uma mensagem para uma fila de mensagens e ela será armazenada até ser processada ou excluída. As filas de mensagens podem ser usadas para dividir um processamento pesado, para armazenar trabalho em *buffers* ou lotes, ou para amenizar picos de cargas de trabalho (Amazon Web Services Incorporated, 2022).

Embora menos comum, chamada de procedimento remoto (RPC) também é utilizado para realizar comunicação síncrona ou assíncrona nos microsserviços. Uma chamada de procedimento remoto se dá quando um programa faz com que um procedimento ou uma sub-rotina execute em um espaço de endereço diferente, comumente em outra máquina numa rede compartilhada. Essa chamada é feita como se fosse um procedimento local, isso é, o programador não precisa explicitar que se trata de um procedimento remoto. (Microsoft Corporation, 2022b).

De acordo com Waseem et al. (2021), API Gateway e Backend for frontend são os padrões de projeto mais utilizados na implementação da comunicação entre microsserviços. Eles são padrões similares - a diferença é que no Backend for Frontend há um gateway para cada tipo de cliente ou serviço de ponta.

5.13 APIs

Considerando que APIs são uma parte crucial no desenvolvimento de microserviços, sendo responsável por grande parte da comunicação que se faz necessária para conectar tantos serviços separados e manter um funcionamento eficiente e livre de falhas, este trabalho apresentará diversas práticas no desenvolvimento de APIs.

5.13.1 Contratos de dados

Contratos de dados representam os acordos formais sobre a estrutura e formato das informações trocadas entre uma API e seus consumidores, bem como definem os campos, tipos de dados e regras de comunicação usadas, garantindo uma interação sem inconsistências. Esses contratos também implicam num compromisso de manter o serviço correspondente funcionando e inalterado. Entretanto, com a evolução de um serviço, surge a necessidade de serem introduzidas melhorias e mudanças que podem impactar nesses contratos (FOWLER; LEWIS, 2014).

Embora o versionamento de APIs seja uma solução tradicional para lidar com essa evolução, no contexto de microsserviços ele deve ser a última alternativa, pois tende a aumentar a

complexidade da manutenção deles. Em vez disso, é recomendável projetar contratos que sejam flexíveis e resilientes a mudanças e introduzir apenas modificações aditivas nos provedores, assim não comprometendo consumidores existentes (FOWLER; LEWIS, 2014).

Contratos de dados orientados ao consumidor (CDC) é uma abordagem para garantir que contratos de comunicação entre serviços estejam alinhados com as necessidades dos consumidores. Em vez de o provedor da API definir unilateralmente o contrato, os consumidores especificam suas expectativas, criando um contrato que o provedor formaliza por meio de testes automatizados a nível de serviço, permitindo que provedores validem continuamente se suas mudanças mantêm a compatibilidade com os consumidores sem aumentar a carga de testes consideravelmente, o que também reduz a necessidade de testes ponta a ponta, que tendem a ser custosos, como discutido na subseção 5.11.3 (ROBINSON, 2006; NEWMAN, 2021).

Ao projetar serviços de forma mais tolerante a mudanças e validar contratos dinamicamente, as equipes podem trabalhar de forma independente e lançar atualizações sem impactar outros sistemas. No entanto, para que essa abordagem funcione bem, é necessário uma boa colaboração entre as equipes e o uso de ferramentas adequadas que facilitem a criação e verificação automática desses contratos. Quando bem aplicado, o CDC promove maior estabilidade em sistemas distribuídos, permitindo que microsserviços evoluam de forma mais previsível e segura. (ROBINSON, 2006)

5.13.2 Formatos de dados

Atualmente JSON é um dos formatos mais populares para troca de dados na web, por ser facilmente lido tanto por humanos quanto por máquinas e não precisar de muitos metadados, como no formato XML. Em APIs, JSON é usado para enviar e receber requisições por meio do protocolo HTTP, sendo uma solução robusta para a comunicação entre cliente e servidor. Embora seja derivado do JavaScript, JSON também é suportado por muitas outras linguagens, seja nativamente ou por meio de bibliotecas. (BOURHIS; REUTTER; VRGOč, 2020)

Outra opção para trocas de dados é usar *Buffers* de protocolo, ou *Protocol buffers*, uma ferramenta de código aberto desenvolvida pelo Google que oferece um método de serialização de dados estruturados para envio de informações. Ela é neutra em linguagem e plataforma, é extensível e funciona como alternativa ao JSON na troca de dados. Essa ferramenta serializa os dados a serem enviados de modo a tornar o pacote mais leve e mais rápido, mas introduz uma complexidade extra. Por introduzir essa complexidade na troca de dados e não ser otimizada para quantidades de dados que excedem alguns megabytes, essa ferramenta não é recomendada para todo caso de uso (Google LLC, 2022).

5.13.3 Códigos de status de respostas HTTP

Esses códigos são números entre 100 e 599 que devem ser enviados com a resposta à requisição, cada um tendo um significado diferente, e cada centena sendo classificada em tipos diferentes de resposta. 100-199 representam respostas de informação, 200-299, respostas de sucesso, 300-399, tipos de redirecionamentos, 400-499, erros por parte do cliente e 500-599, erros por parte do servidor. Esse é um padrão definido na seção 10 da RFC 2616, e facilita o entendimento do cliente sobre o que aconteceu com a requisição à API. (NIELSEN et al., 1999; GUPTA, 2024)

5.13.4 API Gateway

Na arquitetura de microsserviços, muitas vezes a comunicação acontece de muitos pra muitos, podendo um microsserviço enviar e receber requisições para e de múltiplos outros microsserviços. Caso essa comunicação não seja gerenciada de forma adequada, a escalabilidade e segurança do sistema podem ser afetadas negativamente. Conforme mais microsserviços são criados e os já existentes evoluem, torna-se inviável gerenciar tantos *endpoints* em todo microsserviço que precisar usá-los. Uma solução para isso é usar um *API Gateway*. (NEWMAN, 2021)

Um *API Gateway* é um padrão de projeto onde tem-se um servidor que age como uma porta única de entrada para as APIs de um sistema, padronizando e controlando o acesso a elas. Esse *gateway* fica situado entre o consumidor e os microsserviços, e é responsável por redirecionar as requisições recebidas para os microsserviços apropriados, assim o gerenciamento das chamadas pode ser feita em apenas um lugar em vez de em cada consumidor. Além disso, nele também podem ser implementadas camadas de segurança, como autenticação, e de monitoramento, como *logging*.

Outra vantagem é que esse *API Gateway* pode agregar requisições, permitindo que o consumidor envie apenas uma requisição para o *API Gateway* para recuperar informações de diferentes microsserviços, o que normalmente exigiria múltiplas requisições. Nesse caso, quando recebida a requisição do consumidor, o *API Gateway* fica responsável por disparar as requisições correspondentes, agregar as respostas e as devolver ao consumidor.

Entretando, também há desvantagens no uso desse padrão: (1) cria-se um alto acoplamento entre os microsserviços e o *API Gateway*, (2) ele pode se tornar um ponto massivo de falha e (3) se não escalado adequadamente, esse *API Gateway* pode diminuir o de todas as requisições que passarem por ele (Microsoft Corporation, 2022a).

5.13.5 Segurança em APIs

Autenticação e autorização

Incluir autenticação em uma API consiste em exigir uma prova de autorização do uso daquele recurso. A autenticação nas APIs é altamente recomendada por aumentar a segurança de forma simples, e existem várias formas de implementá-la, sendo um dos mais comuns pelo uso de *JSON Web Tokens (JWT)*, definidos na RFC 7519 (NIELSEN et al., 1999).

Validação de entradas

Validar entradas significa verificar as requisições que chegam com o intuito de garantir que elas não contém dados impróprios, tais como injeções de SQL ou *scripting* (execução de uma determinada sequência de comandos) entre sites. Essa validação deve ser implementada tanto em nível sintático como em semântico, isso é, tanto impondo correção da sintaxe quanto impondo correção de valores (GUPTA, 2024).

Certificado Secute Socket Layer (SSL)

Usar um certificado SSL permite que o protocolo HTTPS seja usado em vez do HTTP, criptografando as informações que estão trafegando, aumentando a privacidade da informação trafegada. (GUPTA, 2024)

Limitação de taxa de requisições

Limitar a taxa de requisições é um jeito de proteger a infraestrutura do servidor nos casos de acontecerem grandes fluxos de requisições, tal como em um ataque de *DoS* (negação de serviço). Clientes terão seu acesso bloqueado caso enviem uma quantidade de requisições acima do limite determinado (GUPTA, 2024).

5.13.6 *Caching*

Às vezes referido como *cachear*, salvar informações em *cache* pode melhorar significativemente o tempo de busca da informação pelo cliente. Em uma API podem haver múltiplas requisições para a mesma informação em um curto intervalo de tempo, e para cada requisição será necessário buscar a informação. Entretanto, se a informação estiver salva no *cache*, não será necessário buscar essa informação, o que melhora o tempo de resposta da API, especialmente em *endpoints* que frequentemente retornam a mesma resposta (GUPTA, 2024).

5.13.7 Comprimir os dados

A transferência de cargas grandes pode diminuir a velocidade da API. Comprimir os dados auxilia nesse problema, diminuindo o tamanho da carga e aumentando a velocidade de

transferência. Uma possibilidade é usar buffers de protocolo (GUPTA, 2024).

5.13.8 Documentação

Uma API é apenas tão boa quanto sua documentação, e a falta de informações claras sobre seu uso pode ser um motivo suficiente para não utilizá-la. A documentação deve ser bem formatada e de fácil navegação, preferencialmente usando ferramentas populares para reduzir a curva de aprendizado dos desenvolvedores. Além disso, é importante incluir exemplos práticos de requisições e respostas, permitindo que os usuários testem facilmente a API. (GUPTA, 2024)

5.13.9 Paginar e filtrar

Em APIs, a paginação separa e categoriza resultados, enquanto a filtragem garante que apenas os resultados relevantes de acordo com os parâmetros da requisição são retornados. A paginação e a filtragem de resultados reduzem a complexidade da resposta e a quantidade de dados trafegados, assim poupando recursos (GUPTA, 2024).

5.14 Observabilidade e Monitoramento

A observabilidade se trata de permitir a observação do estado de um sistema por meio da externalização de seu comportamento, e possui 3 pilares - **registros, métricas e rastreamento**. O monitoramento engloba a observabilidade e se trata de acompanhar o estado de um sistema por meio de registros e ações que podem ser tomadas como resposta a eles. O monitoramento é fundamental para promover o funcionamento adequado de um sistema, especialmente os com arquiteturas distribuídas, como a de microsserviços. Com essas arquiteturas, o monitoramento se torna ainda mais importante e complexo, entretanto, traz diversos benefícios, como redução de tempo médio de detecção e reparo de incidentes e favorecimento do cumprimento do Acordo de Nível de Serviço (*Service Level Agreement* - SLA). Além disso, para que se possa ter um alto nível de automação, também é necessário haver um alto nível de monitoramento. As formas mais comuns de implementar monitoramento é por meio de *logs* (registros) e métricas.

Beyer et al. (2016) afirma que os aspectos mais importantes para se monitorar em sistemas distribuídos são latência (tempo de resposta do sistema), tráfego (demanda colocada no sistema), saturação (uso excedente de recursos do sistema) e erros occorridos, sejam erros explicítos (p. ex. erros 500 em uma requisição HTTP), implícitos (p. ex. respostas incorretas à requisição) ou por política (p. ex. tempo de resposta inadequado). O monitoramento desses aspectos muitas vezes são divididos em duas metodologias - RED e USE, que significam *Rate, Errors, Duration* (Taxa, Erros, Duração) e *Utilization, Saturation, Errors* (Utilização, Saturação, Erros), respectivamente. Enquanto RED foca na experiência do usuário, USE foca no funcionamento apropriado da infraestrutura, mas ambos são metodologias abrangentes e complementam um a outra. (BEYER et al., 2016; DAM, 2018)

5.14.1 *Logs* (registros)

Um registro, ou *log*, descreve o que aconteceu em um dado momento em um dado processo, provendo informações rastreáveis sobre o estado e a saúde dele. Manter um histórico de registros de uma aplicação é uma forma simples e eficiente de se implementar monitoramento, e é fortemente indicado para qualquer sistema, especialmente os distribuídos.

Para favorecer uma eficiente escrita, leitura e operação dos registros, eles devem possuir ao menos: um código do evento ocorrido, uma mensagem descritiva, a condição tratada em caso de exceção ou erro e o período de retenção. Também deve-se padronizar o formato dos registros emitidos por todos os microsserviços e diferenciar entradas de erros, de avisos e de informação. Além disso, os registros devem ser agregados e organizados em um único lugar externo aos ambientes de execução da aplicação, para que possam ser facilmente consultados e para evitar perdas de informações, que podem acontecer especialmente em aplicações implantadas em contêineres e com escalamento horizontal. (BEYER et al., 2018)

5.14.2 Métricas

Uma métrica é uma medição de uma propriedade do sistema numa dada janela de tempo, e possui um objetivo específico, seja para questões de desenvolvimento, de infraestrutura ou mesmo de negócios e *business inteligence*. Disponibilizar a porcentagem de uso de CPU em uma máquina, por exemplo, tem o objetivo de informar o operador sobre esse uso para que ele possa decidir que ações precisam ser tomadas. Recomenda-se ter métricas para todo ponto de atenção do sistema, que, é claro, variam de acordo com o sistema e suas regras de negócio, porém geralmente incluem uso de recursos, tempo de resposta e quantidade de acessos.

Enquanto registros precisam ser desenvolvidos, métricas apenas precisam de instrumentação pois muitas ferramentas já possuem as próprias métricas ou já existem métodos consolidados para as obter. Nos servidores web mais populares, por exemplo, as informações básicas sobre uma requisição já são gravadas por padrão.

Além disso, é recomendado usar paineis de controle de alto nível para melhorar a visualização e monitoramento do status da aplicação e diversas outras informações operacionais e de negócio a partir de suas métricas (FOWLER; LEWIS, 2014).

5.14.3 *Tracing* (rastreamento)

Em aplicações com arquitetura distribuida, como os microsserviços, uma única requisição de um usuário irá frequentemente interagir com múltiplos serviços antes de retornar uma resposta, assim havendo possibilidade de ocorrer problemas em múltiplos locais diferentes. Rastreamento trata-se de acompanhar um fluxo transacional (geralmente iniciado por uma requisição de um usuário), desde onde foi originado até onde terminou, atribuindo um identificador único a cada fluxo, que será propagado em cada serviço por onde o fluxo passar. Isso provê visibilidade ponta

a ponta sobre os fluxos no sistema, permitindo que desenvolvedores e operadores identifiquem problemas mais precisa e rapidamente, independentemente de onde eles ocorram.

6

Ferramentas para desenvolvimento de microsserviços

Este capítulo apresenta ferramentas frequentemente usadas e que cumprem propósitos importantes no desenvolvimento de aplicações com arquitetura de microsserviços.

Quando se está procurando por ferramentas para o desenvolvimento de aplicações, a quantidade imensa de opções disponíveis pode ser opressiva. Perguntas como "Para que serve a ferramenta X"? "Qual a diferença entre a ferramenta X e a ferramenta Y", "Em qual cenário eu devo usar a ferramenta X?", "Qual ferramenta funciona melhor com a ferramenta X?"são muito comuns para iniciantes ou para pessoas experientes em poucas ferramentas. E apesar de nem sempre existirem respostas concretas para essas perguntas ou das respostas mudarem com o passar do tempo, esse capítulo provê uma orientação superficial para o desenvolvedor que procure entender o contexto de cada ferramenta e o que elas têm a oferecer.

6.1 Serviços em nuvem

O uso de serviços em nuvem no desenvolvimento e lançamento de aplicações tem crescido cada vez mais na última década. As principais plataformas de nuvem, AWS, Azure e GCP, oferecem uma enorme variedade de serviços que permitem que aplicações sejam criadas, lançadas e mantidas com mais qualidade e de maneira mais simples. De interesse especial às aplicações com arquitetura de microsserviços, eles incluem serviços confiáveis e escaláveis de IaaS ou PaaS, oferencendo desde máquinas virtuais e contêineres até bancos de dados, sistemas de mensagens e soluções *serverless*. Ao usar esses serviços, uma grande parte do trabalho de configuração e gerenciamento da infraestrutura ou plataforma é terceirizada para esses provedores, que quase certamente são melhores em lidar com essas questões. Além disso, a disponibilidade global dos centros de dados dos provedores de nuvem permite que aplicações sejam distribuídas geograficamente, reduzindo a latência e melhorando a experiência do usuário final. (NEWMAN, 2021)

6.2 Frameworks e linguagens de programação

Frameworks desempenham um papel fundamental no desenvolvimento de microsserviços, permitindo que os desenvolvedores criem sistemas modulares, escaláveis e de fácil manutenção de forma mais simples e evitando grande parte do código boilerplate. A escolha do framework e da linguagem pode dependender de diversos fatores, como os requisitos do sistema, a experiência da equipe e as preferências tecnológicas. Existem diversas opções disponíveis no mercado, cada uma com suas características, vantagens e desvantagens, sendo impossível abordar todas em detalhes. Dessa forma, aqui são discutidas apenas algumas das mais populares para o desenvolvimento de microsserviços.

6.2.1 Java e Spring Boot

Java é uma linguagem amplamente utilizada no desenvolvimento de microsserviços devido à sua robustez, escalabilidade e vasta gama de bibliotecas e ferramentas disponíveis. Spring Boot é um dos *frameworks* mais populares para construir microsserviços em Java por simplificar o desenvolvimento de aplicações autônomas e de alto desempenho, permitindo que os desenvolvedores criem rapidamente serviços que podem ser facilmente integrados com outros sistemas. O Spring Boot oferece funcionalidades como configuração automática, injeção de dependência e integração com outros módulos do Spring, como o Spring Cloud, que facilita a implementação de microsserviços com capacidades de descoberta, balanceamento de carga e segurança. (VMware Tanzu, 2025)

A combinação de Java com Spring Boot é especialmente útil para empresas que já possuem uma base de código em Java ou que precisam de um ecossistema maduro com suporte a múltiplas ferramentas de monitoramento, escalabilidade e segurança. Além disso, a linguagem é fortemente tipada, o que ajuda a reduzir erros e a melhorar a manutenibilidade em sistemas grandes e complexos.

6.2.2 Python e Flask ou Django

Python é uma linguagem conhecida por sua simplicidade e rapidez de desenvolvimento, o que a torna uma escolha popular para prototipagem e desenvolvimento de microsserviços, especialmente quando o tempo é um fator crítico. Para a construção de microsserviços, *frameworks* como Flask e Django são frequentemente usados. O Flask é um *framework* minimalista e flexível, ideal para a criação de APIs simples e escaláveis. Ele fornece apenas os recursos essenciais, permitindo que os desenvolvedores escolham bibliotecas adicionais conforme necessário, o que dá flexibilidade para criar soluções sob medida. (PALLETS, 2025)

Por outro lado, Django é um *framework* mais completo e robusto, adequado para aplicações maiores que exigem uma estrutura mais rígida. Embora o Django seja tradicionalmente mais utilizado para aplicações monolíticas, ele pode ser adaptado para um estilo de arquitetura de

microsserviços. Ele vem com uma série de funcionalidades, como mapeamento objeto-relacional (ORM), autenticação e gerenciamento de usuários, que podem ser valiosas em microsserviços que exigem manipulação de dados ou integração com bancos de dados relacionais. (Django Software Foundation, 2025)

6.2.3 Golang

Go, também conhecido como Golang, é uma linguagem desenvolvida pelo Google que se destaca pela sua alta performance e simplicidade. A principal vantagem do Go em microsserviços é a sua capacidade de lidar com concorrência de forma eficiente, com seu modelo de *goroutines* e *channels* (canais), que facilita o desenvolvimento de sistemas altamente concorrentes e escaláveis. O Go é especialmente popular em sistemas que exigem alta taxa de transferência e baixos tempos de latência, como sistemas de *streaming* ou microsserviços que lidam com grandes volumes de dados em tempo real. Além disso, o Go possui uma abrangente biblioteca padrão e ótimas bibliotecas desenvolvidas por terceiros, muitas vezes dispensando a necessidade de um *framework* para a linguagem, tornando o microsserviço ainda mais simples. (Go Team, 2025)

6.2.4 JavaScript/TypeScript com Node.js e Express

Node.js também é muito popular para o desenvolvimento de microsserviços, especialmente em sistemas que exigem alta performance em *I/O* e processamento assíncrono. O Node.js usa um modelo de ciclo de eventos não bloqueante, que é ideal para microsserviços que precisam lidar com uma grande quantidade de requisições simultâneas, como APIs RESTful. Seu ecossistema vasto e a popularidade do JavaScript no desenvolvimento *frontend* também tornam o Node.js uma escolha atraente para equipes que desejam manter uma *stack* unificada em todo o sistema. Além disso, a enorme comunidade de desenvolvedores e a abundância de pacotes disponíveis facilmente instaláveis permitem que os microsserviços sejam desenvolvidos rapidamente e com uma ampla variedade de funcionalidades. O Express, um *framework* minimalista para Node.js, facilita o desenvolvimento de APIs simples e eficientes. (OpenJS Foundation, 2025a; OpenJS Foundation, 2025b)

6.2.5 C# e .NET

C# é uma das linguagens mais utilizadas no ecossistema Microsoft e tem se tornado uma escolha popular para o desenvolvimento de microsserviços, principalmente quando combinada com o *framework* .NET Core, que é uma plataforma de desenvolvimento de código aberto, alto desempenho e com suporte a diversos sistemas operacionais. O ASP.NET Core é um subconjunto do .NET focado em criar aplicações web, incluindo APIs RESTful, que são comumente usadas para comunicação entre microsserviços. Desenvolver microsserviços com .NET ou ASP.NET é especialmente adequado para empresas que já operam em ecossistemas Microsoft. Ambos *frameworks* têm uma comunidade ativa e suporte contínuo, o que os torna uma

escolha confiável para o desenvolvimento de microsserviços. (Microsoft Corporation, 2025b; Microsoft Corporation, 2025a)

6.3 Servidores Web

Servidores web são responsáveis por receber e tratar requisições, agindo como um *middleware* (meio-termo) entre o consumidor e o provedor. Eles podem disponibilizar diversas funcionalidades úteis na comunicação por meio de requisições, tal como *caching*, compressão de dados, limitação de requisições e balanceamento de carga, assim não havendo necessidade de implementá-las manualmente. Além disso, servidores web também podem ser utilizados como *API Gateways*, técnica crucial para gestão da comunicação entre microsserviços, por centralizar o tráfego e se encarregar de redirecionar requisições para os microsserviços adequados.

6.3.1 Nginx ou Apache HTTP Server

O Nginx é um servidor web projetado para lidar com um grande número de conexões simultâneas com consumo eficiente de recursos, tornando-o uma excelente escolha para aplicações escaláveis e dinâmicas. Sua arquitetura baseada em eventos permite melhor desempenho e escalabilidade em comparação com servidores baseados em *threads*, tornando-o ideal para aplicações modernas e de alto tráfego. Além disso, o Nginx pode ser facilmente utilizado como *API Gateway* e *proxy*, técnicas muito pertinentes para auxiliar na comunicação entre microsserviços. (F5 Incorporated, 2025)

O Apache HTTP Server, ou apenas Apache, é um servidor web antigo mas muito bem consolidado e muito usado até hoje. Seu suporte a módulos dinâmicos e seu modelo híbrido de processamento permitem ótima adaptação, mas podem resultar em maior consumo de recursos quando comparado ao NGINX em cenários de alto tráfego. Apesar disso, o Apache ainda é uma ótima opção para aplicações tradicionais ou que necessitem de compatibilidade com tecnologias legadas. (GARNETT; ELLINGWOOD, 2022)

6.4 Bancos de dados persistentes - SQL e NoSQL

Como mencionado na seção 5.6, cada microsserviço deve possuir seu próprio modelo de dados independente, podendo usar bancos de dados distintos. Portanto, a escolha do banco de dados adequado é um aspecto importante no projeto de um microsserviço, sendo importante considerar alguns fatores.

Os bancos de dados relacionais (SQL), como MySQL e PostgreSQL, armazenam dados em tabelas estruturadas, utilizando esquemas predefinidos. Eles são ideais para aplicações que requerem alta consistência e integridade dos dados, especialmente quando há muitas relações entre entidades. Esses bancos seguem o modelo ACID (Atomicidade, Consistência, Isolamento e

Durabilidade), o que os torna indicados para cenários onde transações complexas e confiabilidade são essenciais. (MongoDB, 2024)

Por outro lado, os bancos de dados NoSQL, como MongoDB e Cassandra, oferecem maior flexibilidade ao lidar com dados não estruturados ou semi-estruturados. Eles diferem entre sí em como armazenam informações, podendo ser em documentos JSON (como o MongoDB), em *wide column store* (como o Cassandra), em grafos (como o Neo4j), ou vários outros, sendo a escolha desse tipo de armazenamento também importante. Em contraste com o formato de tabelas estruturadas, esses formatos tendem a facilitar a escalabilidade horizontal e a manipulação de grandes volumes de dados. Bancos de dados NoSQL são especialmente úteis para aplicações que exigem alta disponibilidade e rápida adaptação a mudanças nos dados. (MongoDB, 2024)

O modelo de dados deve ser avaliado para determinar se ele é altamente estruturado e relacional, favorecendo SQL, ou se é mais flexível e variável, onde NoSQL pode ser mais apropriado. Além disso, a escalabilidade é um fator essencial: enquanto bancos SQL geralmente escalam melhor verticalmente (aumentando os recursos de um único servidor), bancos NoSQL são melhor projetados para escalabilidade horizontal (adicionando mais servidores conforme a necessidade). (MongoDB, 2024)

Outro ponto importante é a escolha entre consistência e disponibilidade. Bancos de dados relacionais enfatizam consistência rigorosa, facilitando que todas as transações sejam processadas corretamente antes de serem confirmadas. Já os bancos NoSQL são mais flexíveis nesse quesito. Por serem projetados para serem descentralizados, podem oferecer ou disponibilidade (caso do Cassandra) ou consistência de dados (caso do MongoDB), mas nunca os dois. Assim sendo, se um microsserviço precisa de transações complexas e forte integridade referencial, um banco de dados SQL tende a ser a melhor opção. (BROWN, 2020; MongoDB, 2024)

Ademais, a decisão entre bancos de dados SQL e NoSQL deve ser feita com base nos requisitos específicos de cada microsserviço. Algumas partes do sistema podem se beneficiar da confiabilidade e estrutura dos bancos relacionais, enquanto outras podem precisar da flexibilidade e escalabilidade dos bancos NoSQL. Uma análise cuidadosa desses aspectos ajudará a construir uma arquitetura de microsserviços mais eficiente e escalável, garantindo o desempenho e a confiabilidade da aplicação.

6.5 Bancos de dados em memória - Memcached e Redis

Outro tipo de banco de dados importante para microsserviços são os em memória, como o Memcached e o Redis, que são ideais para *caching*. O Memcached, apoiado pela Netflix, é simples e eficiente para armazenamento de chave-valor puro, sendo altamente escalável e consumindo pouca memória por não armazenar metadados complexos. No entanto, ele não oferece suporte a estruturas de dados avançadas, persistência, replicação nativa ou recursos como pub/sub. Já o Redis é mais versátil, suportando listas, conjuntos, hashes e permitindo também

persistência dos dados no disco, além de replicação e *clustering*, tornando-se útil para aplicações além do cache, como filas e contadores. Enquanto o Memcached tende a ser mais rápido para o propósito puro de *cache* devido à sua leveza, o Redis é mais poderoso e flexível, mas pode exigir mais recursos dependendo do uso. (DORMANDO, 2018; REDIS, 2025)

6.6 Integração contínua e Entrega Contínua (CI/CD)

6.6.1 Sistemas de controle de versão

Um sistema de controle de versão é imprescindível para o desenvolvimento de *software* atualmente e é impossível se ter integração contínua sem um. Os sistemas de controle de versão podem ser categorizados em distribuídos (DVCS), como o Git, ou centralizados (CVCS), como o SVN. Os centralizados mantêm um repositório central onde todas as versões são armazenadas, e os usuários precisam se conectar a ele para obter ou enviar alterações, enquanto nos distribuídos cada usuário possui uma cópia completa do repositório, permitindo trabalho *offline* e melhor gerenciamento de versões.

Atualmente os distribuídos são o padrão no desenvolvimento de *software*, e pouco se ouve falar dos centralizados. O **Git** é, empiricamente, o mais popular entre todos os sistemas de controle de versão, e é uma solução elegante e completa para o controle de versão no desenvolvimento de *software*, seja para um único desenvolvedor ou para equipes numerosas.

6.6.2 Plataformas para CI/CD

GitHub

O GitHub é uma plataforma parcial de CI/CD focada no gerenciamento de código-fonte e é extremamente popular, especialmente para projetos de código aberto. Ela oferece uma interface simples e fácil de usar, assim como diversas ferramentas de colaboração e gerenciamento de repositório. Entretanto, não oferece tantas ferramentas quanto o GitLab, então uma solução mais completa de CI/CD requeriria uso de outras ferramentas. Normalmente o GitHub pode ser usado apenas como serviço na nuvem, mas no plano *enterprise* há opções para auto-hospedagem.

GitLab

O GitLab é uma plataforma de CI/CD abrangente, oferecendo um conjunto mais completo de ferramentas para o ciclo de vida do desenvolvimento de *software*, desde ferramentas de controle de versão até ferramentas de implantação e monitoramento, simplificando a gestão e a integração de ferramentas por estarem todas em uma única plataforma. Além disso, o GitLab possui funcionalidades embutidas para trabalhar com as ferramentas Kubernetes e Docker, facilitando o uso delas e tornando a plataforma especialmente atraente para quem busca uma

solução de CI/CD completa. O GitLab pode ser auto-hospedado ou usado como serviço na nuvem.

6.6.3 Servidores de integração

A escolha do servidor de integração para um microsserviço ou projeto afeta alguns fatores como facilidade de configuração, escalabilidade, suporte a *plugins* (extensões) e integração com outras ferramentas. Aqui são apresentadas 3 das opções mais populares, cada um tendo vantagens e desvantagens dependendo do contexto de uso.

GitHub Actions

O GitHub Actions se destaca pela integração nativa com repositórios do GitHub, tornando o processo de configuração bastante simples para projetos já hospedados no GitHub. Os *pipelines* para um repositório podem ser definidos diretamente nele, usando a linguagem YAML. Sua maior vantagem está na facilidade de uso e na integração com o GitHub, permitindo a execução condicional e configurável do *pipeline* de acordo com eventos do repositório. No entanto, sua desvantagem principal é a dependência do ecossistema GitHub, o que requer uma migração de plataforma para projetos hospedados em outras plataformas de gerenciamento de repositórios.

Jenkins

O Jenkins é um dos sistemas de CI/CD mais bem estabelecidos e flexíveis do mercado. Sendo *open-source* e auto-hospedado, ele oferece uma grande variedade de *plugins* e suporte a diversas ferramentas. Os *pipelines* podem ser definidos para cada projeto usando arquivos jenkinsfile, que são baseados na linguagem Groovy. Sua principal vantagem é a personalização e flexibilidade, podendo ser configurado para praticamente qualquer *pipeline* de CI/CD. No entanto, essa configuração tende a ser mais complexa, exigindo maior conhecimento e manutenção por parte da equipe responsável, além da necessidade de gerenciar sua própria infraestrutura, o que aumenta a complexidade operacional.

GitLab CI/CD

Já o GitLab CI/CD oferece um meio-termo entre a simplicidade do GitHub Actions e a flexibilidade do Jenkins. Ele é integrado ao GitLab, mas não dependente, funcionando nativamente dentro da plataforma porém também podendo ser auto-hospedado, pelo uso da ferramenta GitLab Runner, o que constitui uma de suas maiores vantagens. Semelhante ao GitHub Actions, os *pipelines* podem ser definidos diretamente no repositório do GitLab usando a linguagem YAML. No entanto, para cenários com necessidades bem específicas, pode ser menos aplicável que o Jenkins.

6.7 Comunicação

6.7.1 RPC - gRPC

gRPC é uma ferramenta *open-source* desenvolvida pelo Google que permite o uso de Remote Procedure Call (RPC) entre sistemas distribuídos. Ele usa o formato *Buffers de protocolo* para trocas de dados com menor consumo de recursos. Uma característica importante do gRPC é seu suporte a *streaming* bidirecional e multiplexação, o que o torna ideal para cenários que exigem comunicação em tempo real e transferências de dados grandes entre serviços. Ele suporta tanto comunicação síncrona quanto assíncrona, oferecendo flexibilidade na interação entre os serviços. Além disso, seu sistema de tipagem e suporte embutido para autenticação, balanceamento de carga e descoberta de serviços fazem do gRPC uma ferramenta poderosa para a construção de microsserviços de alto desempenho, escaláveis e seguros. (gRPC Authors, 2025)

6.7.2 Sistemas de mensagens

Sistemas de mensagens são plataformas que permitem a comunicação entre diferentes componentes ou serviços de um sistema distribuído por meio de mensagens. Eles facilitam a comunicação assíncrona entre sistemas, desacoplando produtores e consumidores de mensagens. Esses sistemas são essenciais para arquiteturas escaláveis, como microserviços, permitindo a transmissão eficiente de dados entre diferentes partes do sistema sem interdependências diretas. Aqui são apontados alguns sistemas de mensagens comumente usados em arquiteturas distribuídas, sendo a escolha entre eles dependente da forma das mensagens, requisitos de escalabilidade e se a solução é auto-hospedada ou com infraestrutura gerenciada.

RabbitMQ

O RabbitMQ é um sistema de mensagens baseado no protocolo AMQP que facilita a comunicação assíncrona entre aplicações, oferecendo funcionalidades de publicação e consumo de mensagens. Ele garante confiabilidade na entrega de mensagens e flexibilidade para diversos padrões de troca de mensagens. Contudo, RabbitMQ pode ter limitações de escalabilidade em comparação com sistemas como o Kafka, que são mais adequados para grandes fluxos de dados em tempo real.

Apache Kafka

O Kafka é uma plataforma de *streaming* distribuído de dados, projetada para lidar com grandes volumes de dados em tempo real. Ele é utilizado principalmente para publicar, armazenar e processar fluxos de dados como eventos e logs. O Kafka oferece alta escalabilidade, durabilidade e alta taxa de transferência, suportando casos de uso como rastreamento de atividades de websites, agregação de logs e processamento de fluxos de dados. Com recursos como particionamento e

replicação, o Kafka é ideal para arquiteturas de microserviços e sistemas de processamento de dados distribuídos que têm grandes fluxos de dados. (Apache Software Foundation, 2024)

6.7.2.1 Sistemas de mensagens em provedores na nuvem

Nos provedores de nuvem AWS, Azure e GCP, tem-se o SQS, Azure Service Bus e Google Pub/Sub, respectivamente. Esses são plataformas como serviços (PAAS) que oferecem sistemas de mensagens totalmente gerenciados, abstraindo assuntos de infraestrutura. Eles são escaláveis e fornecem alta disponibilidade, mas podem oferecer menos opções de configuração em comparação com soluções auto-hospedadas como RabbitMQ e Kafka. Enquanto o RabbitMQ se destaca em enfileiramento de baixa latência e Kafka em *streaming* de eventos em tempo real, soluções em provedores na nuvem tendem a se concentrar em simplicidade, escalabilidade e fácil integração com outros serviços em seus respectivos ecossistemas.

6.8 Conteinerização

Docker

O Docker é uma ferramenta de conteinerização amplamente adotada devido à sua facilidade de uso, documentação abrangente e grande comunidade. Ele segue um modelo cliente-servidor, onde um *daemon* (processo em segundo plano) gerencia os contêineres. Os benefícios do Docker incluem configuração simples; implantação e escalamento de contêineres independentemente; grande diversidade de imagens de contêineres disponíveis; e integração com o Kubernetes, uma ferramenta popular e poderosa para gerenciamento de infraestrutura em contêineres. Tais benefícios fazem do Docker uma excelente escolha para o desenvolvimento e implantação de microsserviços. (PERLOW, 2024; SUPPORTFLY, 2024)

Podman

O Podman adota uma arquitetura sem *daemon*, eliminando a necessidade de um serviço central para gerenciar os contêineres. Isso o torna mais seguro, pois permite a execução de contêineres sem privilégios de *root*. O Podman também oferece compatibilidade com a CLI do Docker, facilitando a migração de projetos. Além disso, sua capacidade de gerenciar pods - um grupo de contêineres compartilhando recursos - também o torna uma opção adequada para arquiteturas de microsserviços, especialmente em ambientes com requisitos elevados de segurança. (SUPPORTFLY, 2024)

LXC

O LXC (Linux Containers) adota uma abordagem diferente, fornecendo contêineres em nível de sistema operacional, assim permitindo a criação de ambientes virtuais que se comportam

como sistemas Linux completos. Isso o torna ideal para casos onde se deseja uma alternativa leve às máquinas virtuais ou um acesso altamente eficiente a recursos do *hardware*, como em aplicações com enormes volumes de dados ou cargas de processamento. Entretanto, não é uma opção comum para implantação de microsserviços, que se beneficiam de contêineres mais isolados e especializados, como os oferecidos pelo Docker e pelo Podman. (PERLOW, 2024)

6.8.1 Gerenciamento de contêineres com Kubernetes

O Kubernetes é uma plataforma de orquestração de contêineres de código aberto, projetada para facilitar o gerenciamento de serviços e cargas de trabalho que envolvem contêineres, favorecendo alta disponibilidade e escalabilidade de sistemas distribuídos. Com ele, é possível definir como os contêineres devem ser implantados, monitorados e escalados de maneira declarativa e automatizada, facilitando a administração da infraestrutura. (The Kubernetes Authors, 2024)

O Kubernetes pode ter múltiplos *clusters* de servidores onde os contêineres são executados, podendo distribuir cargas de trabalho de maneira eficiente e favorecendo a alta disponibilidade das aplicações. Os principais conceitos do Kubernetes são os *pods*, que agrupam contêineres, os *services*, que intermediam a comunicação interna e/ou externa ao *cluster*, e os *deployments*, que controlam a atualização e escalamento dos contêineres. (The Kubernetes Authors, 2024)

Embora o Kubernetes compartilhe algumas características com plataformas de *Platform* as a Service (PaaS), ele não impõe restrições sobre os tipos de aplicações suportadas, não constrói ou implanta código-fonte automaticamente e não fornece serviços internos, como bancos de dados ou *middlewares*. Diferente de sistemas de orquestração tradicionais, o Kubernetes foca na convergência do estado desejado, favorecendo um ambiente robusto, flexível e adequado para aplicações modernas distribuídas. (The Kubernetes Authors, 2024)

Dessa forma, o Kubernetes pode ser utilizado em arquiteturas de microsserviços não só por facilitar a administração da infraestrutura, mas também pelas diversas ferramentas valiosas embutidas, como o gerenciamento de configurações, descoberta de serviços, balanceamento de carga, recuperação automática de falhas, alocação dinâmica de volumes e discos, entre outros. Além disso, o Kubernetes suporta diferentes ambientes de execução, como servidores físicos, máquinas virtuais e serviços de nuvem, assim sendo uma solução abrangente e flexível.

Kubernetes em provedores na nuvem

Provedores na núvem como AWS, Azure e GCP oferecem serviços gerenciados de Kubernetes, assim reduzindo ainda mais a complexidade operacional associada à instalação, configuração e manutenção da infraestrutura. Esses serviços facilitam a implementação de clusters Kubernetes, integrando-se com os ecossistemas das respectivas plataformas.

Além disso, os provedores podem oferecer recursos adicionais, como balanceadores de

carga gerenciados e integração com sistemas de monitoramento e segurança. A elasticidade proporcionada pela nuvem garante que aplicações com arquitetura de microsserviços possam escalar globalmente sem a necessidade de gerenciar servidores físicos. Ademais, ao usar o Kubernetes em provedores na nuvem a portabilidade ainda é mantida, podendo as aplicações serem facilmente migradas entre provedores ou para infraestrutura híbrida, assim evitando o que é conhecido como *vendor lock-in* (bloqueio de fornecedor).

6.9 Observabilidade e Monitoramento

6.9.1 Métricas - Prometheus e Grafana

Prometheus é uma ferramenta *open-source* de monitoramento e alerta projetada para coletar e analisar dados de séries temporais (métricas). Ele funciona coletando métricas de diversas fontes por meio de *endpoints* instrumentados, armazenando esses dados em sua base de dados de séries temporáis (TSDB) que permite consultas eficientes. O Prometheus permite consultas avançadas usando sua linguagem própria, o PromQL, possibilitando a criação de métricas personalizadas e a definição de alertas e é amplamente usado para monitorar infraestrutura, aplicativos e serviços, especialmente em ambientes distribuidos ou na nuvem. (Prometheus, 2025)

O Grafana é uma plataforma de visualização que se integra ao Prometheus e a diversas outras fontes de dados. Com ele, é possível construir *dashboards* interativos e personalizados, favorecendo uma visão detalhada do desempenho da aplicação e da infraestrutura, e configurações de alertas e notificações automáticas, facilitando a identificação rápida de problemas.

A combinação do Prometheus com o Grafana é amplamente utilizada em arquiteturas de microsserviços, pois permite monitoramento escalável e descentralizado. Com a instrumentação adequada, é possível monitorar métricas de CPU, memória, latência de requisições, status de serviços, uso de banco de dados e muito mais.

Por serem open-source, essa combinação de ferramentas oferece uma solução robusta e de baixo custo que é amplamente adotada para monitoramento de sistemas. A facilidade de integração com outras tecnologias e a grande comunidade de suporte fazem do Prometheus e do Grafana uma escolha ideal para monitoramento moderno de aplicações.

6.9.2 Logging - Grafana Loki

Grafana Loki, ou apenas Loki, é uma *stack* para agregação e indexação de *logs*, sendo composto por um conjunto de componentes independentes. Ele funciona recebendo um fluxo de *logs* a partir de um agente que os captura da aplicação, e em seguida faz a indexação apenas de metadados deles, como um *label* (rótulo), que apontam para os dados do *log*, que são compactados e armazenados como objeto, assim consumindo pouco armazenamento. Além de

consumir pouco armazenamento, o Loki também faz uso eficiente de memória; tem possibilidade para multilocação, ou seja, consegue escutar múltiplas aplicações enviando logs ao mesmo tempo, o que é importante em sistemas distribuídos; é altamente escalável, permitindo diferentes configurações de implantação; e permite que diversas outras ferramentas de observabilidade se conectem com ele. Entretanto, ele usa a própria linguagem de consulta - LogQL, o que pode dificultar o aprendizado da ferramenta. Além disso, por indexar apenas metadados, a busca de logs por conteúdo é mais dificil, e é preciso que os logs sejam bem estruturados e rotulados para ser eficiente. (Grafana Labs, 2025)

6.9.3 Logging - Graylog

O Graylog utiliza o Elasticsearch para armazenar os *logs*, que é uma ferramenta de pesquisa e análise de dados distribuída e altamente escalável, otimizada para realizar buscas e consultas rápidas em grandes volumes de dados. Esse modelo é poderoso para consultas complexas em *logs*, mas pode ser mais exigente em termos de configuração e gerenciamento de recursos. O Graylog também possui sua própria interface de usuário para gestão dos *logs*, diferente do Loki que precisa da integração com o Grafana para oferecer uma. Além disso, ele também fornece funcionalidades de alertas, *dashboards* personalizados e visualizações interativas que permitem que os usuários realizem análises complexas dos *logs*. Dessa forma, essa ferramenta é ideal para análise de *logs* complexos e é muito utilizada em ambientes corporativos onde a análise detalhada de *logs* é crítica para a resolução de problemas, auditorias e monitoramento de segurança. (Graylog Incorporated, 2025)

6.9.4 Tracing (rastreamento) - Jaeger

O Jaeger é uma ferramenta *open-source* de rastreamento desenvolvida para monitorar e rastrear fluxos em sistemas distribuídos, oferecendo informações detalhadas sobre cada passo do fluxo, assim facilitando a identificação de gargalos, falhas e latências que podem comprometer a performance do sistema. (The Jaeger Authors, 2025)

Essa ferramenta oferece uma interface gráfica que permite visualizar os rastreamentos de uma forma clara, com diagramas de sequência e linhas do tempo, o que facilita a análise do comportamento dos serviços e a detecção de problemas em pontos específicos da infraestrutura. Ele é compatível com diversas linguagens de programação e é amplamente utilizado em arquiteturas de microsserviços, também podendo ser integrado com outras ferramentas de monitoramento e observabilidade, como o Prometheus e o Grafana, para fazer a correlação de rastreamentos com *logs* e métricas, assim fornecendo uma visão ainda mais ampla do sistema. (The Jaeger Authors, 2025)

7

Aplicação exemplar com arquitetura de microsserviços

Este capítulo apresenta a aplicação exemplar com arquitetura de microsserviços desenvolvida.

A aplicação desenvolvida trata-se de um sistema web de *E-commerce*. Nela, um cliente da loja pode buscar e comprar produtos, enquanto um administrador pode gerenciar produtos e usuários cadastrados, tudo a partir de uma interface de usuário em um navegador. O código fonte está disponível no repositório do GitHub com link https://github.com/Jp9910/microservices_project.

7.1 A aplicação e a divisão em microsserviços

A composição da aplicação pode ser vista no diagrama de componentes da aplicação, na Figura 4. Já a divisão dos microsserviços, em formato de pacotes, pode ser vista no diagrama de pacotes da aplicação, na Figura 5, que fornece mais detalhes sobre a estrutura interna de cada microsserviço e como eles se conectam. Ademais, as responsabilidades de cada microsserviço são explicadas a seguir

Microsserviço de loja

Esse é um microsserviço de negócio que trata do armazenamento e lógica de negócios relacionada a produtos e pedidos.

Microsserviço de carrinho

Esse é um microsserviço de negócio que trata do armazenamento e lógica de negócios relacionada ao carrinho.




Figura 4 – Diagrama de componentes da aplicação exemplar

Fonte: Autor

Microsserviço de usuários

Esse é um microsserviço de negócio que trata do armazenamento e lógica de negócios relacionada aos usuários do sistema, incluindo autenticação.

Microsserviço financeiro

Esse é um microsserviço de negócio que trata apenas do processamento fictício do pagamento de um pedido.

Microsserviço de clientes

Esse é um microsserviço de ponta que clientes da loja podem acessar para realizar todas as operações relevantes a eles a partir de uma interface de usuário, tal como ver e buscar produtos, adicionar produtos ao carrinho e realizar um pedido a partir de um carrinho.

Microsserviço de administração

Esse é um microsserviço de ponta que administradores da loja podem acessar para realizar todas as operações relevantes a eles a partir de uma interface de usuário, tal como adicionar e alterar produtos do catálogo da loja e adicionar ou alterar usuários do sistema.

Para a divisão do sistema em torno dos domínios de negócio, foram aplicados alguns princípios do *Domain-Driven Design*, sendo inicialmente identificados os seguintes contextos




Figura 5 – Diagrama de pacotes da aplicação exemplar

Fonte: Autor

limitados (*bounded contexts*): Catálogo, Carrinho, Pedidos, Pagamentos, *Marketing* e Usuários. Cada um desses poderia compor um microsserviço, entretanto, para não criar um sistema complexo demais para ser desenvolvido por apenas uma pessoa em pouco tempo, alguns desses foram mesclados em um só ou descartados. *Marketing* parecia ser o contexto menos relevante para o funcionamento adequado do sistema, portanto foi descartado. Também foi decidido que o contexto de pedidos poderia ser mesclado ou com o contexto de produtos ou com o de carrinho por serem relacionados.

Determinar qual desses dois contextos seria o mais apropriado para a mescla não foi fácil, e certamente terá implicações futuras na manutenção do sistema. No fim, foi decidido que o contexto de pedidos seria mesclado com o contexto de catálogo, assim sendo responsabilidade do microsserviço de loja, pois pedidos são naturalmente relacionados com produtos e necessitam de alta consistência por envolver múltiplas operações, assim tornando o banco de dados relacional, que foi o escolhido para o armazenamento dos produtos, mais apropriado para o caso, em contraste com o banco de dados NoSQL, que foi o escolhido para armazenamento dos carrinhos. Essa decisão está refletida no diagrama de classes da aplicação, apresentado na Figura 6, onde podem ser vistos as classes, controladores e fronteiras da aplicação e suas associações.

Além disso, para favorecer uma linguagem ubíqua, os nomes das representações das

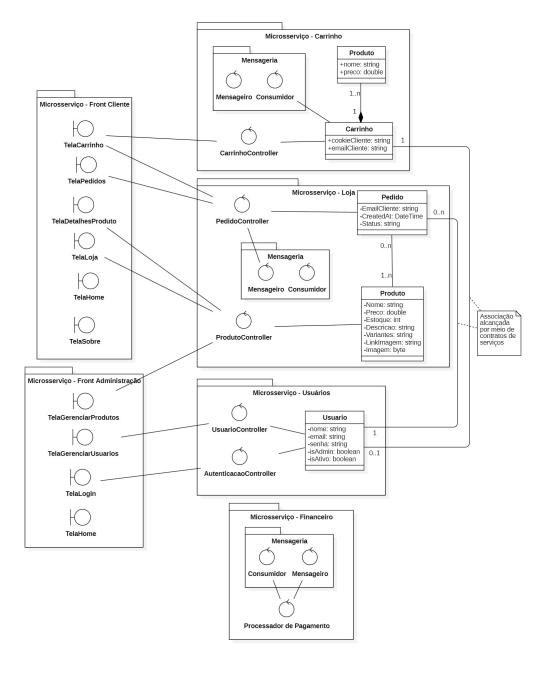


Figura 6 – Diagrama de classes da aplicação exemplar

Fonte: Autor

entidades em cada microsserviço foram definidos de acordo com o domínio em questão. Um usuário, por exemplo, é chamado de usuário (do sistema) no microsserviço de usuários, porém no microsserviço de loja, ele é chamado de cliente.

Por fim, também é mostrado a seguir o diagrama de sequência de um dos casos de uso da aplicação. Apesar da aplicação dispor de diversos casos de uso, foi escolhido apenas o mais complexo para ser mostrado, pois o foco não é explorar a lógica de negócios representada; e sim ilustrar como geralmente acontecem a comunicação e o fluxo de mensagens em uma arquitetura

de microsserviços como resultado da ação de um usuário. Trata-se do diagrama de sequência do caso de uso de realizar uma compra no carrinho, que pode ser visto na Figura 7

Sequencia Comprac Carrinho Pedido Controller Pedido Mensageiro (MS-Loja) Consumidor (MS-Carrinho) Carrinho Consumidor (MS-Financeiro) Processador de Pagamento Consumidor (MS-Financeiro) Processador de Pagamento Consumidor (MS-Financeiro) Processador de Pagamento Consumidor (MS-Loja)

1. Precenter Dasso Pagamento 2: Dados Carrinho APagamento são Valdos)

4. Pedido Crindo

4. Pedido Crindo

5. Fedido Crindo

8. Excluir Carrinho

10. Processar Pagamento

11. Resultado Processamento

12. Alterar Status Pedido

13. Dados Inveltidos

14. Pedido Crindos

15. Pedido Crindos

16. Dados Inveltados

17. Dados Inveltados

18. Dados Invelhance

18. Dados Inveltados

19. Dados Inveltados

Figura 7 – Diagrama de sequência do caso de uso de realizar uma compra no carrinho

Fonte: Autor

7.2 Práticas, ferramentas e padrões usados

7.2.1 Frameworks e linguagens de programação

Para demonstrar a flexibilidade da arquitetura de microsserviços e como oportunidade para aprender novos *frameworks*, foram usados diferentes *frameworks* e linguagens de programação para os microsserviços. O microsserviço de usuários foi feito com Java e Spring Boot, o de loja com C# e .NET, o de carrinho com TypeScript, Node.JS e Express, o financeiro com TypeScript e Node.JS, o de ponta de cliente com ReactJS e o de ponta de administração com Angular.

7.2.2 Servidor web e API gateway

Como servidor web foi usado o Nginx nos serviços de ponta para servir os arquivos estáticos, por ser simples de configurar e oferecer diversas funcionalidades proveitosas para microsserviços. Além disso, ele também foi usado no componente Gateway como um API *gateway* para o intermédio da comunicação entre os serviços de ponta e os serviços de negócio, redirecionando as requisições dos serviços de ponta para os serviços de negócio apropriados.

7.2.3 Bancos de dados e descentralização dos dados

Foram usados diferentes instâncias e tecnologias de bancos de dados na aplicação desenvolvida, assim proporcionando a descentralização dos dados. Nos microsserviços de loja e de usuários foi usado o banco de dados relacional PostgreSQL, tanto pela simplicidade de

configuração quanto pela consistência de dados de operações mais importantes, como criação de um pedido ou de um usuário.

No microsserviço de carrinho foi usado o banco de dados NoSQL MongoDB porque um carrinho tem uma estrutura mais dinâmica, com itens podendo ter estruturas diferentes e sendo adicionados, alterados e removidos frequentemente.

Além disso, também foi usado o banco de dados em memória Memcached para realizar o *caching* da busca de produtos no microsserviço de loja, assim proporcionando menor latência e consumo de recurso nessa operação que é executada com alta frequência.

7.2.4 Metodologia 12-fatores

A maioria dos fatores da metodologia 12-fatores foram considerados e cumpridos no desenvolvimento da aplicação: I - Base de código única; II - Dependências portáteis e isoladas; III - Externalizar configurações; IV - Serviços de apoio são anexos; V - Separação entre construção, lançamento, e execução; VI - Processos sem estado (os microsserviços de ponta guardam a informação do usuário no navegador do cliente); VIII - simultaneidade; IX - Descartabilidade; X - Paridade de ambientes de execução; XI - *Logs*; e XII - Processos administrativos.

7.2.5 Contêinerização e orquestração de contêineres

Para a contêinerização dos microsserviços, foi usado o Docker. Para cada microsserviço foram declarados *Dockerfiles*, que contém instruções usadas pelo Docker para a criação de imagens de contêineres do Docker, que foram usadas como artefatos que podem ser implantados em contêineres. Essas imagens foram salvas no repositório gratuito de imagens DockerHub, assim ficando facilmente disponíveis para serem baixadas onde necessário.

Além disso, no repositório principal e no de cada microsserviço foi criado um *Docker-Compose*, um arquivo que serve como forma declarativa de definir conjuntos de contêineres do Docker a serem executados. Esses conjuntos foram definidos de forma a executar todos os contêineres necessários para o funcionamento completo de um microsserviço, usando as imagens criadas pelo *Dockerfile*. No repositório principal, ele inclui toda a aplicação. O *Docker-Compose* facilita e portabiliza a configuração de um ambiente de execução e geralmente é usado para ambientes de desenvolvimento pois não provê muitas garantias de estabilidade e escalabilidade, porém também pode ser usado para outros ambientes se desejado.

Para o ambiente de produção, foram criados arquivos de configuração do Kubernetes para orquestração dos contêineres, assim podendo-se obter diversos dos benefícios apontados na subseção 6.8.1. Esses arquivos estão no repositório principal e definem como os contêineres serão implantados e mantidos pelo Kubernetes. Os artefatos usados para implantação dos contêineres de produção são os mesmos usados pelo *Docker-Compose*, apenas com variáveis de ambiente diferentes, assim proporcionando ambientes de execução semelhantes.

Sendo assim, configurações sensíveis e de ambiente foram externalizadas, e todos os microsserviços podem ser facilmente iniciados para diferentes ambientes de execução, apenas sendo necessário definir algumas variáveis de ambiente, como uma senha do banco de dados.

7.2.6 CI/CD

Foi usado o Git como sistema de controle de versão e o GitHub para gerenciamento de repositórios em todos os microsserviços, com configuração de proteção do ramo principal do repositório para evitar *commits* indevidos, assim sendo necessário a criação de um *pull request* e aprovação dele por um administrador do repositório para integração do novo código no ramo principal.

No microsserviço de ponta de administração também foi implementado um *pipeline* de CI/CD com 3 etapas sequenciais, com uso do GitHub Actions como servidor de integração para executar o *pipeline* automaticamente a cada novo *commit* recebido. A primeira etapa executa o *linting* nos arquivos JavaScript com o ESLint e os testes de unidade com a biblioteca Karma; a segunda etapa faz a construção e *upload* do artefato com o novo código. A terceira etapa usa esse artefato para criar uma imagem de container Docker pronta para implantação, que é subida para o DockerHub, um repositório gratuito de imagens Docker, assim podendo ser recuparada facilmente em outras máquinas.

7.2.7 Organização do código - Multirepo

Para a organização do código, foi utilizada a técnica Multirepo com os repositórios no GitHub. Cada microsserviço possui um único repositório independente, porém também há um repositório principal que contém referências para os repositórios de cada microsserviço, reunindo tudo que é necessário para executar a aplicação inteira.

7.2.8 Comunicação síncrona

A comunicação síncrona é usada apenas entre os microsserviços de ponta e de negócios, proporcionando *feedback* rápido sobre as operações executadas e melhorando a experiência do usuário. Essa comunicação foi implementada por meio da exposição de APIs seguindo os princípios REST, que podem receber requisições HTTP com dados no formato JSON. Depois de recebida a requisição, é feita a verificação de existência do recurso requisitado e a validação dos dados recebidos. Caso sejam válidos, a lógica de negócios adequada é executada e possíveis resultados retornados são devidamente paginados pelo controlador e comprimidos pelo API *gateway*. No microsserviço de usuários, também é verificada a permissão de acesso do cliente requisitante ao recurso, por meio de *tokens* JWT. Assim, antes também é necessário a autenticação do cliente por meio de e-mail e senha, que se validados com sucesso, será respondido com um token JWT que deve ser enviado em todas as próximas requisições.

7.2.9 Comunicação assíncrona

Para a comunicação entre os microsserviços de negócio foi implementada exclusivamente comunicação assíncrona por meio do sistema de mensagens RabbitMQ, assim cada microserviço pode operar de forma independente, diminuindo o acoplamento entre eles e aumentando a escalabilidade do sistema. Também foram usadas configurações de mensagens de modo que se o RabbitMQ for afetado por uma falha ou sair do ar, as mensagens não serão perdidas. Sendo assim, as interações entre serviços não dependem de respostas imediatas, contribuindo para uma maior resiliência e tolerância a falhas. Portanto, é possível, por exemplo, que o microsserviço de loja se comunique com o microsserviço de carrinho mesmo que esse último esteja fora do ar, pois ao ser enviada uma mensagem pela loja, ela será armazenada no RabbitMQ, e quando o microsserviço de carrinho eventualmente voltar a funcionar ele pode buscar as mensagens armazenadas e as processar de maneira adequada.

7.2.10 Monitoramento

Para o monitoramento do sistema, foi utilizado Prometheus para captura e processamento de métricas, Loki para agregação dos *logs*, e Grafana para busca e exibição gráfica desses. Por falta de tempo, apenas o microsserviço de usuários foi configurado para expor métricas para o Prometheus e para enviar os *logs* para o Loki, mas ambos estão prontos para receberem informações de outros microsserviços também.

Primeiramente foi configurada a integração entre o *spring boot* e o Prometheus a partir da extensão Actuator, que expõe métricas da aplicação web Java. O prometheus, então, captura essas métricas, as agrega e as disponibiliza no formato de séries temporais. Em seguida, foi instalada e configurada a extensão Loki4j, que faz o envio automático de *logs* de uma aplicação Java para o Loki, por meio da API que ele expõe. Após isso, foi criado um *dashboard* personalizado no Grafana que busca as métricas expostas pelo Prometheus, por meio da linguagem PromQL, e os *logs* agregados no Loki, por meio da linguagem LogQL, para então os exibir graficamente. Por fim, também foi criado um *script* para simulação do uso do microsserviço de usuários, para que possam ser geradas algumas métricas e *logs* interessantes para serem visualizados no *dashboard* criado, como pode ser visto na Figura 8. Instruções de como configurar o Grafana e importar o *dashboard* personalizado estão no arquivo README do repositório do projeto.

Ademais, também foi implementado *logging* no API *gateway*, usando a funcionalidade embutida do Nginx que grava *logs* no sistema de arquivos com informações de origem da requisição, recurso solicitado, agente usado, entre outros, assim provendo informações de todas as requisições que passam por ele.



Figura 8 – Visualização do dashboard do Grafana personalizado

Fonte: Autor

7.2.11 Padrões de projeto

O uso de uma arquitetura de microsserviços bem dividida facilita a aplicação de padrões organizacionais, com alguns emergindo naturalmente. Dessa forma, a aplicação obedece a alguns padrões de projeto, citados a seguir.

MVC

Na aplicação exemplar, foi utilizado o padrão MVC (*Model-View-Controller*) sempre que aplicável para organizar a estrutura dos pacotes de forma clara e modular. Devido à divisão natural do tipo de arquitetura tratado, nem todo microsserviço possui essas 3 camadas; nos microsserviços de negócio, por exemplo, não existe a camada *View*. Assim sendo, a divisão foi feita da maneira aplicável a cada microsserviço, garantindo que as responsabilidades fossem bem definidas e que alterações em uma camada não afetassem as demais. Essa divisão também pode ser visualizada no diagrama de pacotes da aplicação.

SOLID

Apesar de nem todos os microsserviços usarem exclusivamente o *design* orientado a objetos (JavaScript, por exemplo, é multi-paradigma, mas tem uma tendência para uma abordagem mais funcional), os princípios SOLID também foram adotados no desenvolvimento da aplicação, assim prezando para que cada módulo tivesse apenas uma responsabilidade, que o sistema fosse

extensível sem a necessidade de grandes alterações e que as abstrações fossem priorizadas sobre as implementações concretas.

O acesso ao banco de dados em memória no microsserviço de loja, por exemplo, foi encapsulado em uma classe genérica que implementa as funções específicas do banco de dados usado, assim podendo ser substituido por outro com a necessidade apenas de alterar a configuração do banco de dados e a lógica contida dentro dessa classe encapsuladora. Além disso, a dependência dessa classe é injetada diretamente no controlador que a usará, assim seguindo o princípio da inversão da dependência.

CLEAN

Também foram implementados alguns princípios da arquitetura CLEAN, o que favoreceu ainda mais a independência entre os componentes e camadas do sistema. Ao aplicar esse padrão, foi possível isolar a lógica de domínio das dependências externas, como *frameworks* e bancos de dados. Essa separação resultou em um design mais robusto, onde a lógica de negócio permanece centralizada e facilmente testável, permitindo a evolução contínua dos microserviços com risco reduzido de efeitos colaterais indesejados. Nos microsserviços de loja e usuários, por exemplo, é possível alterar o banco de dados usado sem ser necessário alterações no código, apenas na configuração e dependências.

8

Conclusão

Como pôde ser constatado, a escolha da arquitetura de uma aplicação não é uma decisão simples. Assim como quase tudo na computação, trata-se de *tradeoffs*; e para determinar se a arquitetura a ser escolhida é adequada, precisa-se entender seus benefícios, riscos, desvantagens e desafios para os aplicar ao contexto tratado. Apesar de não existir uma definição formal para a arquitetura de microsserviços, foram apresentadas muitas características frequentes que a diferencia de outras abordagens arquiteturais, tais como a componentização, flexibilidade de ferramentas e alta complexidade.

Também foram apresentadas e discutidas diversas práticas comumente usadas no desenvolvimento de aplicações com arquitetura de microsserviços, sendo observada uma ampla concordância entre pesquisadores e praticantes de microsserviços acerca do que é comum, do que é bem-visto, do que é considerado um anti-padrão, e de quais são os desafios envolvidos. Entretanto, foi descoberto um ponto em que há mais espaço para discussão e pesquisa - a prática de se começar uma arquitetura de microsserviços por uma arquitetura monolítica até que a aplicação e seus domínios já estejam bem definidos -, pois foi observado um certo nível de discordância entre os autores das referências utilizadas sobre o que é ou não necessário para sustentar uma arquitetura de microsserviços desde o início do desenvolvimento da aplicação e quais seriam as razões para se adotar ou não essa arquitetura.

Além disso, foram apresentadas diversas ferramentas que cumprem propósitos importantes para o sucesso de uma arquitetura de microsserviços, desde *frameworks* de desenvolvimento até ferramentas de monitoramento, cujos contextos, benefícios e desvantagens devem ser compreendidos, para assim favorecer a escolha das mais adequadas ao contexto tratado.

Foram escolhidas algumas dessas ferramentas e combinadas com certas práticas apresentadas e alguns padrões de projeto para ser desenvolvida, implantada e monitorada uma aplicação web de *E-commerce* com arquitetura de microsserviços. Ela foi desenvolvida em diferentes linguagens de programação; usa múltiplos bancos de dados; usa um API *gateway* para intermédio

Capítulo 8. Conclusão 78

das requisições; cumpre a maioria dos fatores da metodologia 12-fatores; é contêinerizada e orquestrada; usa comunicação síncrona por meio de requisições HTTP e assíncrona por meio do sistema de mensagens RabbitMQ onde apropriado; segue certas práticas de CI/CD; e conta com monitoramento em um dos microsserviços, assim tendo-se uma aplicação com arquitetura de microsserviços completa e robusta, porém ainda com bastante espaço para melhorias.

Como trabalhos futuros, na aplicação exemplar a autenticação de consumidores das APIs e o monitoramento dos microsserviços podem ser implementados para todos os microsserviços, em vez de apenas no de usuários, para se ter mais segurança e confiabilidade no sistema; os contextos de produtos e de pedidos podem ser separados para microsserviços diferentes, em vez de estarem juntos no microsserviço de loja, assim melhorando a coesão do sistema; e por fim, o sistema também pode ser expandido de diversas maneiras, como, por exemplo, pela criação de um microsserviço de recomendações, que poderia ser responsável por usar informações do carrinho ou dos pedidos de um cliente para enviar recomendações direcionadas a ele, por meio de *e-mails*.

Dessa forma, este trabalho explorou de forma abrangente a arquitetura de microsserviços e todos os objetivos estabelecidos foram cumpridos. Entretanto, a tecnologia evolui rápida e constantemente, assim sempre surgindo novos padrões, práticas e ferramentas para o desenvolvimento de *software*, especialmente para sistemas complexos como os que usam a arquitetura de microsserviços; e se manter a par deles é uma eterna tarefa dos profissionais da computação.

Amazon Web Services Incorporated. *Filas de mensagens*. 2022. Disponível em: https://aws.amazon.com/pt/message-queue/>. Citado na página 48.

Apache Software Foundation. *Kafka 2.0 Documentation*. 2024. Disponível em: https://kafka.apache.org/20/documentation.html. Citado na página 63.

ASSUNçãO, W. K. G. et al. How do microservices evolve? an empirical analysis of changes in open-source microservice repositories. *Journal of Systems and Software*, v. 204, Oct 2023. Disponível em: https://www.sciencedirect.com/science/article/pii/S0164121223001838>. Citado 2 vezes nas páginas 8 e 25.

BELLEMARE, A. *Building Event-Driven Microservices*. [S.l.]: "O'Reilly Media, Inc.", 2020. ISBN 9781492057840. Citado 2 vezes nas páginas 8 e 23.

BEYER, B. et al. Site reliability engineering: How google runs production systems. In: _____. 1. ed. O'Reilly Media, 2016. cap. 6. ISBN 9781491929124. Disponível em: https://sre.google/sre-book/monitoring-distributed-systems/. Citado na página 52.

BEYER, B. et al. The site reliability workbook: Practical ways to implement sre. In: _____. O'Reilly Media, 2018. cap. 4. ISBN 9781492029458. Disponível em: https://sre.google/workbook/monitoring/>. Citado na página 53.

BHATNAGAR, S. *The Art of Decoding Microservices*. [S.l.]: Springer Nature, 2025. ISBN 9798868812675. Citado 2 vezes nas páginas 8 e 24.

BOURHIS, P.; REUTTER, J. L.; VRGOč, D. JSON: Data model and query languages. *Information Systems*, v. 89, p. 101478, Mar 2020. ISSN 03064379. Disponível em: https://linkinghub.elsevier.com/retrieve/pii/S0306437919305307>. Citado na página 49.

BROUSSE, N. The issue of monorepo and polyrepo in large enterprises. In: *Proceedings of the Conference Companion of the 3rd International Conference on Art, Science, and Engineering of Programming*. New York, NY, USA: Association for Computing Machinery, 2019. (Programming '19). ISBN 9781450362573. Disponível em: https://doi.org/10.1145/3328433.3328435. Citado 2 vezes nas páginas 44 e 45.

BROWN, K. *Choosing the Right Databases for Microservices*. 2020. Disponível em: https://www.ibm.com/think/insights/choosing-the-right-databases-for-microservices. Citado na página 59.

DAM, J. *The RED Method: How to Instrument Your Services*. 2018. Disponível em: https://grafana.com/blog/2018/08/02/the-red-method-how-to-instrument-your-services/. Citado na página 52.

Django Software Foundation. *Django*. 2025. Disponível em: https://www.djangoproject.com/>. Citado na página 57.

DORMANDO. *About Memcached*. 2018. Disponível em: https://www.memcached.org/about. Citado na página 60.

EVANS, E. *Domain-driven Design : Tackling Complexity in the Heart of Software*. 1. ed. Boston, Mass. ; Munich: Addison-Wesley, 2003. ISBN 9780321125217. Citado na página 34.

- F5 Incorporated. *Beginner's Guide*. 2025. Disponível em: https://nginx.org/en/docs/beginners_guide.html. Acesso em: 15 Mar 2025. Citado na página 58.
- FAMILIAR, B. *Microservices, IoT, and Azure: Leveraging DevOps and Microservice Architecture to Deliver SaaS Solutions*. Berkeley, CA: Apress, 2015. ISBN 978-1-4842-1275-2. Disponível em: https://link.springer.com/book/10.1007/978-1-4842-1275-2. Citado 7 vezes nas páginas 7, 17, 20, 27, 28, 29 e 47.
- FERNANDEZ, T.; ACKERSON, D. *Release Management for Microservices*. 2022. Disponível em: https://semaphoreci.com/blog/release-management-microservices>. Citado na página 45.
- FOWLER, M. *Continuous Integration*. 2006. Blog do Martin Fowler. Disponível em: https://martinfowler.com/articles/continuousIntegration.html>. Acesso em: 12 Nov 2022. Citado 3 vezes nas páginas 40, 41 e 46.
- FOWLER, M. *Blue Green Deployment*. 2010. Blog do Martin Fowler. Disponível em: https://martinfowler.com/bliki/BlueGreenDeployment.html>. Acesso em: 15 Mar 2025. Citado na página 42.
- FOWLER, M. *Frequency Reduces Difficulty*. 2011. Blog do Martin Fowler. Disponível em: https://martinfowler.com/bliki/FrequencyReducesDifficulty.html>. Acesso em: 24 Feb 2025. Citado na página 42.
- FOWLER, M. *Continuous Delivery*. 2013. Blog do Martin Fowler. Disponível em: https://martinfowler.com/bliki/ContinuousDelivery.html>. Acesso em: 12 Nov 2022. Citado na página 41.
- FOWLER, M. *Microservice Prerequisites*. 2014. Blog do Martin Fowler. Disponível em: https://martinfowler.com/bliki/MicroservicePrerequisites.html>. Acesso em: 06 Oct 2022. Citado 3 vezes nas páginas 32, 33 e 34.
- FOWLER, M. *Microservice Tradeoffs*. 2015. Blog do Martin Fowler. Disponível em: https://martinfowler.com/articles/microservice-trade-offs.html>. Acesso em: 13 Nov 2022. Citado 2 vezes nas páginas 15 e 30.
- FOWLER, M. *Monolith first*. 2015. Blog do Martin Fowler. Disponível em: https://martinfowler.com/bliki/MonolithFirst.html>. Acesso em: 09 Nov 2022. Citado 4 vezes nas páginas 30, 31, 32 e 33.
- FOWLER, M.; LEWIS, J. *Microservices*. 2014. Blog do Martin Fowler. Disponível em: https://martinfowler.com/articles/microservices.html>. Acesso em: 06 Nov 2022. Citado 9 vezes nas páginas 27, 28, 29, 37, 38, 47, 48, 49 e 53.
- GARNETT, A.; ELLINGWOOD, J. *Apache vs Nginx: Practical Considerations*. 2022. Disponível em: https://www.digitalocean.com/community/tutorials/apache-vs-nginx-practical-considerations>. Acesso em: 15 Mar 2025. Citado na página 58.
- GitLab Incorporated. *What is CI/CD?* 2022. GitLab Topics. Disponível em: https://about.gitlab.com/topics/ci-cd/. Citado 3 vezes nas páginas 39, 40 e 41.

GitLab Incorporated. *What is DevOps?* 2022. GitLab Topics. Disponível em: https://about.gitlab.com/topics/devops/>. Citado na página 44.

Go Team. *Go Programming Language*. 2025. Disponível em: https://golang.org/>. Citado na página 57.

Google LLC. *Overview* | *Protocol Buffers*. 2022. Disponível em: https://developers.google.com/protocol-buffers/docs/overview. Citado na página 49.

Grafana Labs. *Loki overview* | *Grafana Loki documentation*. 2025. Disponível em: https://grafana.com/docs/loki/latest/get-started/overview/. Citado na página 66.

Graylog Incorporated. *What Is Graylog*. 2025. Disponível em: https://go2docs.graylog.org/current/what_is_graylog/what_is_graylog.htm. Citado na página 66.

gRPC Authors. *What is gRPC?* | *Core concepts, architecture and lifecycle*. 2025. Disponível em: https://grpc.io/docs/what-is-grpc/core-concepts/>. Citado na página 62.

GUPTA, L. *RESTful web API design*. 2024. Disponível em: https://restfulapi.net/ rest-api-best-practices/>. Acesso em: 16 Mar 2025. Citado 3 vezes nas páginas 50, 51 e 52.

Harness Incorporated. *Continuous Delivery vs. Continuous Deployment: What's the Difference?* 2021. Harness topics. Disponível em: https://harness.io/blog/continuous-delivery-vs-continuous-deployment>. Citado na página 38.

HODGSON, P. *Feature Toggles (aka Feature Flags)*. 2017. Blog do Martin Fowler. Disponível em: https://martinfowler.com/articles/feature-toggles.html>. Acesso em: 15 Mar 2025. Citado na página 43.

HOFFMAN, K. *Building Microservices with ASP.NET Core*. [S.l.]: "O'Reilly Media, Inc.", 2017. ISBN 9781491961681. Citado 2 vezes nas páginas 8 e 23.

HUMBLE, J.; FARLEY, D. *Continuous delivery: reliable software releases through build, test, and deployment automation.* Upper Saddle River, NJ: Addison-Wesley, 2010. ISBN 9780321601919. Citado 5 vezes nas páginas 8, 22, 40, 41 e 42.

IBM. *CAP Theorem*. 2022. Disponível em: https://www.ibm.com/think/topics/cap-theorem. Citado na página 30.

LUMETTA, J. *Microservices for Startups: Should you always start with a monolith?* 2018. Disponível em: https://buttercms.com/books/microservices-for-startups/should-you-always-start-with-a-monolith/>. Citado na página 33.

Microsoft Corporation. *The API gateway pattern versus the Direct client-to-microservice communication*. 2022. Disponível em: https://learn.microsoft.com/en-us/dotnet/architecture/microservices/architect-microservice-container-applications/direct-client-to-microservice-communication-versus-the-api-gateway-pattern. Citado na página 50.

Microsoft Corporation. *gRPC*. 2022. Disponível em: https://learn.microsoft.com/pt-br/dotnet/architecture/cloud-native/grpc. Citado na página 48.

Microsoft Corporation. *ASP.NET Core*. 2025. Disponível em: https://dotnet.microsoft.com/en-us/apps/aspnet>. Acesso em: 14 Mar 2025. Citado na página 58.

Microsoft Corporation. *Microsoft .NET*. 2025. Disponível em: https://dotnet.microsoft.com/en-us/learn/dotnet/what-is-dotnet>. Acesso em: 14 Mar 2025. Citado na página 58.

Middleware Lab. *What are Microservices? How Microservices architecture works*. Middleware Lab, 2021. Disponível em: https://middleware.io/blog/microservices-architecture/>. Citado na página 12.

MongoDB. *NoSQL Vs SQL Databases*. 2024. Disponível em: https://www.mongodb.com/resources/basics/databases/nosql-explained/nosql-vs-sql. Citado na página 59.

MONOLITHIC application. 2022. Page Version ID: 1118196758. Disponível em: https://en.wikipedia.org/w/index.php?title=Monolithic_application&oldid=1118196758. Citado na página 15.

NEWMAN, S. *Building Microservices: Designing Fine-Grained Systems*. 2. ed. Sebastopol, Ca: O'reilly Media, 2021. ISBN 9781492034025. Citado 10 vezes nas páginas 7, 17, 21, 22, 30, 46, 47, 49, 50 e 55.

NIELSEN, H. et al. *Hypertext Transfer Protocol* – *HTTP/1.1*. [S.l.], 1999. Disponível em: https://datatracker.ietf.org/doc/rfc2616/. Citado 2 vezes nas páginas 50 e 51.

OpenJS Foundation. *Express.js*. 2025. Disponível em: https://expressjs.com/>. Acesso em: 14 Mar 2025. Citado na página 57.

OpenJS Foundation. *Node.js*. 2025. Disponível em: https://nodejs.org/en/docs/>. Acesso em: 14 Mar 2025. Citado na página 57.

Oracle Corporation. topic, *Learn about architecting microservices-based applications on Oracle Cloud*. Oracle Corporation, 2021. Disponível em: https://docs.oracle.com/pt-br/solutions/learn-architect-microservice. Citado 5 vezes nas páginas 12, 18, 28, 38 e 45.

PALLETS. *Flask*. 2025. Disponível em: https://flask.palletsprojects.com/en/2.0.x/. Citado na página 56.

PENNINGTON, J. *The Eight Phases of a DevOps Pipeline*. 2020. Disponível em: https://medium.com/taptuit/the-eight-phases-of-a-devops-pipeline-fda53ec9bba. Citado na página 44.

PERLOW, J. *Linux Containers vs. Docker: Which One Should You Use?* 2024. Disponível em: https://www.docker.com/blog/lxc-vs-docker/. Citado 2 vezes nas páginas 63 e 64.

Prometheus. *Overview* | *What is Prometheus*. 2025. Disponível em: https://prometheus.io/docs/introduction/overview/. Citado na página 65.

Red Hat Incorporated. *What is CI/CD*? 2022. Red Hat Topics. Disponível em: https://www.redhat.com/en/topics/devops/what-is-ci-cd. Citado 3 vezes nas páginas 38, 39 e 41.

REDIS. *Get Started with Redis Community Edition*. 2025. Disponível em: https://redis.io/docs/latest/get-started/. Citado na página 60.

RICHARDSON, C. *Microservices Pattern: Monolithic Architecture pattern*. 2018. Disponível em: http://microservices.io/patterns/monolithic.html>. Citado 2 vezes nas páginas 16 e 17.

RICHARDSON, C. *Microservices Patterns: with Examples in Java*. Shelter Island, New York: Manning Publications, 2019. ISBN 9781617294549. Citado 2 vezes nas páginas 8 e 22.

RICHARDSON, M. A. *Top 10 Challenges of Using Microservices for Managing Distributed Systems*. 2021. Disponível em: https://www.spiceworks.com/tech/data-management/articles/top-10-challenges-of-using-microservices-for-managing-distributed-systems/. Acesso em: 10 Nov 2022. Citado na página 30.

ROBINSON, I. *Consumer-Driven Contracts: A Service Evolution Pattern*. 2006. Blog do Martin Fowler. Disponível em: https://martinfowler.com/articles/consumerDrivenContracts.html. Acesso em: 14 Mar 2025. Citado na página 49.

RODRIGUES, R. de C. 2016. Disponível em: https://www.fiap.com.br/2016/10/03/metodologia-12-fatores/. Citado na página 35.

SATO, D. *Canary Release*. 2014. Blog do Martin Fowler. Disponível em: https://martinfowler.com/bliki/CanaryRelease.html. Acesso em: 15 Mar 2025. Citado na página 43.

SINGH, N.; DAWOOD, Z.; The Micronaut® Foundation. *Building Microservices with Micronaut*®. [S.l.]: Packt Publishing Ltd, 2021. ISBN 9781800567399. Citado 2 vezes nas páginas 8 e 22.

SIWIEC, D. *Monorepos for Microservices Part 1: Do or do not?* 2021. Disponível em: https://danoncoding.com/monorepos-for-microservices-part-1-do-or-do-not-a7a9c90ad50e. Citado na página 45.

SOLDANI, J.; TAMBURRI, D. A.; HEUVEL, W.-J. V. D. The pains and gains of microservices: a systematic grey literature review. *Journal of Systems and Software*, Dec 2018. Citado 2 vezes nas páginas 8 e 24.

SUPPORTFLY. *Podman Vs Docker: a Comprehensive Comparison*. 2024. Disponível em: https://medium.com/@supportfly/podman-vs-docker-a-comprehensive-comparison-77b1b41e67e0>. Citado na página 63.

The Jaeger Authors. *Jaeger* | *Features*. 2025. Disponível em: https://www.jaegertracing.io/docs/1.22/features/. Citado na página 66.

The Kubernetes Authors. *Kubernetes* | *Overview*. 2024. Disponível em: https://kubernetes.io/docs/concepts/overview/#why-you-need-kubernetes-and-what-can-it-do. Citado na página 64.

TILKOV, S. *Don't start with a monolith*. 2015. Blog do Martin Fowler. Disponível em: https://martinfowler.com/articles/dont-start-monolith.html>. Acesso em: 09 Nov 2022. Citado 2 vezes nas páginas 32 e 33.

VMware Tanzu. *Spring Boot*. 2025. Disponível em: https://spring.io/projects/spring-boot>. Citado na página 56.

WASEEM, M.; LIANG, P.; SHAHIN, M. A systematic mapping study on microservices architecture in devops. *Journal of Systems and Software*, v. 170, p. 110798, 2020. ISSN 0164-1212. Disponível em: https://www.sciencedirect.com/science/article/pii/S0164121220302053. Citado 2 vezes nas páginas 7 e 21.

WASEEM, M. et al. Design, monitoring, and testing of microservices systems: The practitioners' perspective. *Journal of Systems and Software*, v. 182, p. 111061, 2021. ISSN 0164-1212. Disponível em: https://www.sciencedirect.com/science/article/pii/S0164121221001588. Citado 4 vezes nas páginas 7, 12, 21 e 48.

WIGGINS, A. topic, *The Twelve-Factor App.* 2017. Disponível em: https://12factor.net/>. Acesso em: 21 Oct 2022. Citado na página 35.

XU, C. et al. CAOPLE: A Programming Language for Microservices SaaS. In: 2016 IEEE Symposium on Service-Oriented System Engineering (SOSE). [S.l.: s.n.], 2016. p. 34–43. Citado 2 vezes nas páginas 12 e 30.